

Predição de Letalidade Hospitalar por Infarto Agudo do Miocárdio no SUS

Carolina Nascimento Silva^{1*}; Maíra Blumer Fatoretto²

^{1*} MBA em Ciência de Dados e Analytics, USP/ESALQ. E-mail autor correspondente:
nascimento.carolina202@gmail.com

² Doutora em Estatística pela Universidade de São Paulo (USP).

Predição de Letalidade Hospitalar por Infarto Agudo do Miocárdio no SUS

Resumo

O infarto agudo do miocárdio caracteriza-se pela alta letalidade no sistema público brasileiro, cujo desfecho é determinado não apenas por fatores clínicos individuais, mas também pela capacidade estrutural do hospital responsável pelo atendimento. Este estudo investigou a associação entre estrutura hospitalar, tempo de internação e risco de letalidade por infarto agudo do miocárdio no estado de São Paulo, entre 2015 e 2025. Foram integrados dados do Sistema de Informações Hospitalares e do Cadastro Nacional de Estabelecimentos de Saúde (CNES), vinculando mensalmente características de infraestrutura às internações. Foram utilizados os algoritmos Regressão Logística Múltipla, Random Forest, XGBoost e LightGBM para estimar o risco individual de óbito. As probabilidades preditas foram divididas em tercís e relacionadas ao escore de estrutura hospitalar. O XGBoost apresentou o melhor desempenho no teste temporal (AUC-ROC = 0,78). A associação entre estrutura e mortalidade variou conforme o nível de risco clínico ($p < 0,001$), com maior diferença entre pacientes de alto risco: 13,5% de óbitos em hospitais de baixa estrutura e 20,0% em hospitais de estrutura muito alta. A análise de Cox também indicou que o efeito da estrutura sobre o risco de óbito variou ao longo da internação ($p < 0,001$). Os resultados sugerem que características individuais não são suficientes para explicar a letalidade hospitalar e que a maior mortalidade em hospitais de maior estrutura entre pacientes de alto risco pode refletir a concentração de casos complexos nesses centros, e não um efeito direto da estrutura sobre o risco individual.

Palavras-chave: Inteligência Artificial; Saúde Pública; Análise de Sobrevivência; Modelagem Preditiva; Iniquidade Estrutural em Saúde; DATASUS.

Prediction of Hospital Lethality by Acute Myocardial Infarction in the Public Health System

Abstract

Acute myocardial infarction is characterized by high lethality in the Brazilian public health system, with outcomes determined not only by individual clinical factors but also by the structural capacity of the hospital responsible for providing care. This study investigated the association between hospital structure, length of stay, and the risk of lethality from acute myocardial infarction in the state of São Paulo, between 2015 and 2025. Data from the Hospital Information System and the National Registry of Health Establishments (CNES) were integrated, linking infrastructure characteristics to hospitalizations on a monthly basis. Multiple Logistic Regression, Random Forest, XGBoost, and LightGBM algorithms were used to estimate individual mortality risk. The predicted probabilities were divided into tertiles and related to the hospital structure score. XGBoost showed the best performance on the temporal test set (ROC-AUC = 0.78). The association between structure and mortality varied according to the level of clinical risk ($p < 0.001$), with the greatest difference among high-risk patients: 13.5% mortality in hospitals with low structural capacity and 20.0% in hospitals with very high structural capacity. Cox analysis also indicated that the effect of hospital structure on mortality risk varied throughout hospitalization ($p < 0.001$). The results suggest that individual characteristics are not sufficient to explain hospital lethality and that the higher mortality in hospitals with greater structural capacity among high-risk patients may reflect the concentration of complex cases in these centers, rather than a direct effect of hospital structure on individual risk.

Keywords Artificial Intelligence; Public Health; Survival Analysis; Predictive Modeling; Structural Health Inequity; DATASUS.

Considerações Iniciais

Segundo dados da Organização Mundial da Saúde (2025), doenças cardiovasculares foram responsáveis por aproximadamente 17 milhões de mortes ao redor do globo anualmente. Dentre essas enfermidades, destacou-se o infarto agudo do miocárdio [IAM], que, somado aos acidentes vasculares cerebrais, respondeu por quatro em cada cinco mortes por doenças cardíacas. No cenário nacional, estimou-se a ocorrência de 300 mil a 400 mil casos de IAM anualmente, dos quais aproximadamente cinco em cada sete evoluíram para óbito, conforme dados do Ministério da Saúde (2025). Além da perda de vidas, o infarto impõe grande impacto financeiro e estrutural ao sistema público de saúde, devido ao alto custo de internações e procedimentos de alta complexidade e às sequelas que reduzem a qualidade de vida dos sobreviventes (Sasso et al., 2024).

Fatores fisiológicos e clínicos, como diabetes e hipertensão, somados a fatores comportamentais, como sedentarismo e altos níveis de estresse, são documentados na literatura como causas de maior risco cardiovascular (Ribeiro et al., 2021; Précoma et al., 2019). Contudo, a sobrevivência ao IAM ultrapassou as questões fundamentais do paciente: fatores estruturais, relacionados à infraestrutura hospitalar, mostraram-se determinantes para o desfecho, a ponto de a literatura apontar que um mesmo perfil clínico pode resultar em desfechos distintos conforme a capacidade assistencial do hospital (Escosteguy et al., 2002; Cavalheiro et al., 2024). Essa constatação sugere que a estratificação de risco centrada exclusivamente no paciente, ainda que amplamente adotada, captura apenas parte da explicação sobre a letalidade hospitalar por IAM.

Com o avanço da tecnologia, a integração de algoritmos de aprendizado de máquina e métodos de Ciência de Dados demonstrou potencial crescente no suporte à estratificação de risco de pacientes com patologias cardiovasculares, permitindo identificar padrões em grandes volumes de dados e subsidiar o desenvolvimento de modelos preditivos capazes de auxiliar na formulação de políticas públicas (Koike, 2025; Gioia et al., 2022). No cenário nacional, o Departamento de Informática do Sistema Único de Saúde [DATASUS] disponibiliza bases que integram informações sobre morbimortalidade, internações hospitalares e infraestrutura de saúde, permitindo análises que unam variáveis clínicas, demográficas e estruturais.

Ainda assim, apesar da relevância dessas bases e do crescente número de estudos voltados à modelagem preditiva em saúde cardiovascular (Koike, 2025), permanecem limitadas as pesquisas que investigam como o efeito de fatores estruturais sobre a mortalidade se modifica conforme o nível de risco clínico, indo além de análises que tomam ambos os fatores de forma isolada, como observado em Escosteguy et al. (2002). Da mesma forma, a literatura nacional, fortemente caracterizada por análises epidemiológicas descritivas e estáticas sobre o desfecho de óbito na alta hospitalar (e.g., Cavalheiro et al.,

2024) ainda carece de investigações que integrem diferentes sistemas de informação do SUS para avaliar a variação do risco de óbito de forma dinâmica ao longo da internação. Essa lacuna limita a compreensão sobre como desigualdades estruturais influenciam os desfechos clínicos de forma contínua, e não apenas como condição fixa observada na admissão.

Diante do cenário exposto, este trabalho teve como objetivo investigar se, e de que forma, o risco de letalidade hospitalar por IAM no Sistema Único de Saúde é modulado pela estrutura hospitalar e pelo tempo de internação. Para tal, propôs-se a integração dos dados de desfechos clínicos do Sistema de Informações Hospitalares [SIH] às variáveis de infraestrutura do Cadastro Nacional de Estabelecimentos de Saúde [CNES], referentes ao estado de São Paulo, no período de 2015 a 2025. Especificamente, buscou-se: (i) construir e comparar modelos supervisionados de aprendizado de máquina capazes de estimar o risco individual de óbito hospitalar; (ii) investigar se o efeito da estrutura hospitalar sobre a mortalidade observada varia conforme o nível de risco clínico do paciente; e (iii) aplicar a análise de sobrevivência para avaliar se e como o risco de óbito se modifica ao longo do tempo de permanência hospitalar.

Para atingir tais objetivos, foram implementados algoritmos de aprendizado de máquina para análise supervisionada, utilizando-se a Regressão Logística Múltipla com penalização de classes como modelo de referência, contraposta a métodos baseados em árvores de decisão com Gradient Boosting, o Extreme Gradient Boosting [XGBoost], o Light Gradient Boosting Machine [LightGBM] e o Random Forest. O desempenho preditivo dos modelos foi avaliado de forma abrangente: além da Área Sob a Curva ROC (AUC-ROC), foram reportadas a Área Sob a Curva Precision-Recall (PR-AUC), especialmente informativa em cenários de desbalanceamento severo de classes (Saito e Rehmsmeier, 2015), e a calibração de probabilidades pelo Brier Score. A interpretabilidade dos preditores foi obtida pela adoção de valores SHapley Additive exPlanations (SHAP), utilizados para identificar os principais determinantes do risco e subsidiar a análise de justiça algorítmica das predições. Para a modelagem temporal, aplicou-se o modelo semiparamétrico de Riscos Proporcionais de Cox, complementado pelo estimador de Kaplan-Meier.

Por fim, cabe destacar as limitações inerentes ao método proposto. A precisão dos modelos preditivos encontra-se condicionada à qualidade da coleta e do preenchimento originais das bases secundárias do DATASUS, estando o conjunto de dados sujeito a potenciais subnotificações, ruídos de codificação administrativa e ausência de variáveis de evolução clínica laboratorial intra-hospitalar. Da mesma forma, o indicador de estrutura hospitalar utilizado, embora clinicamente orientado, constitui uma simplificação de uma realidade multidimensional. Portanto, o tratamento rigoroso dos dados e a atenção às

escolhas metodológicas visaram mitigar tais distorções, promovendo inferências úteis para o planejamento de políticas públicas.

Implementação de Algoritmo(s) de Machine Learning

A presente pesquisa caracterizou-se como um estudo quantitativo e aplicado, fundamentado em dados secundários de acesso público. A metodologia adotada partiu de um levantamento de registros administrativos do Sistema Único de Saúde e teve como delineamento principal a implementação e comparação de algoritmos de aprendizado de máquina voltados à predição de risco de óbito hospitalar por Infarto Agudo do Miocárdio, complementada pela investigação de como esse risco é modulado pela estrutura hospitalar e pelo tempo de internação.

[FIGURA: diagrama de fluxo do pipeline DATASUS FTP → conversão .dbc/.csv → tradução de códigos → limpeza SIH → integração CNES (chave hospital×mês) → seleção de features → split temporal → modelagem/SHAP → análise de interação → sobrevivência.]

Descrição das bases de dados

Foram utilizadas duas bases de dados públicas mantidas pelo Departamento de Informática do Sistema Único de Saúde, acessadas via protocolo de transferência de arquivos [FTP]. A primeira base utilizada foi o Sistema de Informações Hospitalares [SIH], que registra as internações hospitalares financiadas pelo SUS por meio das Autorizações de Internação Hospitalar, cada registro corresponde a uma internação e contém informações clínicas, sociodemográficas e administrativas do paciente. Foram coletados os registros referentes a todos os meses do período compreendido entre 2015 e 2025, no estado de São Paulo, totalizando 28.284.570 internações em formato bruto.

A segunda base utilizada foi o Cadastro Nacional de Estabelecimentos de Saúde [CNES], registro oficial que documenta a infraestrutura das unidades de saúde no Brasil. Diferentemente de uma abordagem de corte único, empregou-se aqui a granularidade mensal do CNES, ou seja, uma fotografia da infraestrutura hospitalar para cada combinação de estabelecimento e mês de competência, o que permitiu vincular cada internação à condição estrutural real do hospital no momento exato de sua ocorrência, e não a um retrato posterior ou anterior do estabelecimento. Foram utilizadas cinco tabelas do CNES (Estabelecimentos, Leitos, Equipamentos, Serviços Especializados e Habilitações), descritas na Tabela 1.

Tabela 1. Descrição das tabelas do Cadastro Nacional de Estabelecimentos de Saúde

Tabela	Sigla	Conteúdo	Registros
Estabelecimentos	ST	Dados cadastrais principais de cada hospital	62.522
Equipamentos	EQ	Equipamentos existentes e em uso	552.840
Habilitações	HB	Habilitações e certificações do estabelecimento	1.471.830
Leitos	LT	Quantidade de leitos por tipo (clínico, cirúrgico, Unidade de Terapia Intensiva)	2.213.516
Serviços Especializados	SR	Serviços ofertados pelo estabelecimento	427.109

Extração, integração e tratamento dos dados

Todo o ciclo de extração, transformação e carga foi operacionalizado em linguagem Python (versão 3.11). Os arquivos brutos, disponibilizados em formato .dbc (formato proprietário comprimido do DATASUS), foram descomprimidos e convertidos para o formato .csv. Em razão de o DATASUS armazenar variáveis categóricas como códigos numéricos sem significado direto (por exemplo, sexo ou raça/cor codificados como dígitos), foi implementado um motor de tradução baseado nos dicionários oficiais da plataforma (arquivos .def e .cnv), convertendo os códigos em descrições legíveis.

Adicionalmente aos dicionários institucionais do DATASUS, foi realizada uma etapa complementar de tradução semântica das variáveis codificadas que compõem o espaço preditivo do modelo. Os códigos de procedimentos hospitalares foram mapeados à tabela oficial do Sistema de Gerenciamento da Tabela de Procedimentos, Medicamentos e OPM do SUS [SIGTAP], convertendo códigos numéricos para definições escritas. Os diagnósticos secundários foram traduzidos conforme a Classificação Internacional de Doenças, 10ª revisão [CID-10]. As variáveis de infraestrutura do CNES receberam nomenclaturas descritivas referentes às habilitações e serviços registrados, por exemplo, habilitacao_802 foi renomeada para "Habilitação Alta Complexidade em Cardiologia". Essa etapa visa diretamente à interpretabilidade dos gráficos, garantindo que as contribuições de cada variável sejam legíveis e clinicamente contextualizadas no relatório de resultados.

O tratamento de dados ausentes seguiu um critério de corte bem fundamentado na literatura (Kuhn e Johnson, 2013; Hair et al., 2018) entre as duas bases: colunas com proporção de valores ausentes superior a 70% foram removidas, por se considerar que a

imputação de variáveis com densidade informacional inferior a 30% comprometeria a validade científica do modelo. Foram selecionadas para análise apenas as internações cujo diagnóstico principal correspondia ao Infarto Agudo do Miocárdio, identificado pelo prefixo I21 da CID-10. Das 28.284.570 internações brutas do SIH, 416,027 corresponderam a esse critério, representando 1.47% do total. Foram adicionalmente excluídos 660 registros de pacientes com idade inferior a 18 anos, por se tratar de evento biologicamente distinto do IAM adulto, frequentemente associado a cardiopatias congênitas (Jayaprasad, 2016), resultando em uma base de 415.367 internações de adultos.

A integração entre as bases SIH e CNES foi realizada por meio de uma chave composta pelo código CNES do estabelecimento e a competência temporal (ano-mês), o que garantiu que a infraestrutura atribuída a cada internação refletisse o mês exato de ocorrência da admissão, eliminando o vazamento temporal que ocorreria caso um único retrato da infraestrutura hospitalar fosse aplicado indistintamente a internações ocorridas em anos diferentes.

```
# Criando a chave de competência (YYYYMM) no SIH para coincidir com chave do CNES
df_sih['competencia']=df_sih['ano_competencia']+df_sih['mes_competencia']

# Garantindo que os tipos das chaves sejam idênticos em ambas as bases
df_sih['codigo_cnes']= df_sih['codigo_cnes'].astype(str).str.strip().str.zfill(7)
df_sih['competencia'] = df_sih['competencia'].astype(str).str.strip()

df_cnes['codigo_cnes']= df_cnes['codigo_cnes'].astype(str).str.strip().str.zfill(7)
df_cnes['competencia'] = df_cnes['competencia'].astype(str).str.strip()

# Left Join no nível Hospital-Mês
df_base_modelagem = pd.merge(
    df_sih,
    df_cnes,
    on=['codigo_cnes', 'competencia'],
    how='left',
    suffixes=('', '_cnes')
)
```

Algoritmo 1. Script para o criação de competência temporal e junção de bases. Fonte: Dados originais da pesquisa.

A base de dados integrada final apresentou taxa de correspondência superior a 98% entre os registros do SIH e do CNES. Identificou-se assimetria na distribuição da variável-alvo, com 376.410 registros de alta (90,62%) e 38.957 óbitos (9,38%), configurando um desbalanceamento de classes de aproximadamente 9:1 que exigiu tratamento específico nas etapas subsequentes de modelagem.

Construção do indicador de estrutura hospitalar

Para investigar a hipótese central deste trabalho, de que o desfecho clínico depende não apenas do risco individual do paciente, mas também da capacidade estrutural do hospital que o atendeu, foi construído um escore de estrutura hospitalar (0 a 3) a partir de três critérios do CNES: (i) habilitação em cardiologia intervencionista (cateterismo/cirurgia cardiovascular, exceto transplante); (ii) disponibilidade de leito complementar (Unidade de Terapia Intensiva); e (iii) habilitação para transplante cardíaco. A soma dos três critérios originou quatro categorias: Baixa (escore 0), Média (escore 1), Alta (escore 2) e Muito Alta (escore 3). A aplicação deste escore revelou que, embora a quantidade física de hospitais na rede seja relativamente dividida entre as categorias Alta (39,7%, n=201) e Baixa (37,4%, n=189), o volume de atendimentos é massivamente concentrado nos centros de maior capacidade: 70,2% (291.644) de todas as internações ocorreram em hospitais de estrutura Alta e 19,2% (79.749) naqueles de estrutura Muito Alta. As estruturas Baixa e Média responderam, respectivamente, por apenas 4,4% (18.424) e 6,2% (25.550) dos casos avaliados. Diferentemente das features descritas na subseção seguinte, o escore de estrutura hospitalar não foi incluído como preditor no modelo de classificação, sendo deliberadamente reservado como variável moderadora para a análise de interação entre risco clínico e capacidade assistencial, apresentada na seção de Resultados.

Engenharia de Features

Além das variáveis originais das bases SIH e CNES, foram construídas features derivadas com vistas a incorporar conhecimento clínico ao processo de modelagem, aumentando a capacidade do modelo de capturar dimensões de risco não diretamente observáveis nos registros administrativos brutos.

Além das variáveis originais das bases SIH e CNES, foram construídas features derivadas com vistas a incorporar conhecimento clínico ao processo de modelagem, aumentando a capacidade do modelo de capturar dimensões de risco não diretamente observáveis nos registros administrativos brutos. O escore_fragilidade foi calculado como função linear ponderada da idade e do número de comorbidades secundárias registradas na internação, operacionalizado por meio da expressão: $\text{escore} = 0,4 \times \text{idade_normalizada} + 0,6 \times \text{n_comorbidades_normalizado}$. Esse índice sintetiza em um único atributo a vulnerabilidade clínica preexistente do paciente, inspirando-se nos critérios de fragilidade amplamente referenciados na literatura geriátrica e cardiológica (Précoma et al., 2019). O volume_hospitalar_anual foi estimado como o número total de internações por IAM registradas em cada estabelecimento no ano da admissão do paciente, funcionando como proxy de experiência institucional e volume-resultado no manejo da síndrome coronariana aguda, relação amplamente documentada na literatura de qualidade assistencial em

cardiologia. A `razao_leitos_uti` foi calculada como a proporção de leitos de Unidade de Terapia Intensiva em relação ao total de leitos hospitalares registrados no CNES no mês da internação, capturando a capacidade relativa de suporte intensivo de cada estabelecimento. As três features foram derivadas exclusivamente a partir de variáveis disponíveis no momento da admissão, sem acesso a informações de evolução intra-hospitalar, preservando a integridade preditiva do modelo e a inexistência de vazamento de dados.

Seleção de variáveis e pré-processamento

O conjunto de dados inicial, resultante da integração entre as bases SIH e CNES e enriquecido com as features derivadas descritas na subseção anterior, foi submetido a um processo de redução de dimensionalidade estruturado em etapas sequenciais. Removeram-se, em primeiro lugar, as variáveis caracterizadas como vazamento de dados (data leakage): campos relacionados ao desfecho ou conhecidos apenas a posteriori (no momento da alta ou óbito), como o motivo de saída, a data de saída, o valor total faturado da internação e o tempo total de permanência e suas variáveis derivadas (dias de permanência e indicadores de uso acumulado de UTI). A exclusão dessas variáveis foi motivada pelo fato de que o objetivo do modelo é realizar a predição estritamente com base nas características disponíveis no momento da admissão do paciente. Sua manutenção anteciparia informações futuras, inflando artificialmente o desempenho preditivo. Eliminaram-se, em seguida, as colunas constantes e quase-constantes, definidas por concentrarem mais de 98% dos registros em uma única categoria. Descartaram-se ainda variáveis textuais de alta cardinalidade não computáveis.

Diferentemente de abordagens convencionais que empregam filtros de correlação linear prévia (Pearson), optou-se por não aplicar corte de correlação como etapa de seleção de variáveis para os modelos baseados em árvores. Essa decisão fundamenta-se no fato de que algoritmos como XGBoost e LightGBM capturam relações não-lineares e interações multidimensionais por meio do Information Gain (critérios de Gini e Entropia), sendo capazes de operar sobre espaços de alta dimensionalidade e descartar, via ganho de informação nulo, as variáveis que não contribuem para a predição (Chen e Guestrin, 2016; Ke et al., 2017). Adicionalmente, ambos os modelos contam com regularização nativa nos parâmetros `reg_alpha` (L_1) e `reg_lambda` (L_2), tornando-os intrinsecamente robustos ao ruído dimensional. Um pré-corte linear poderia, nesse contexto, eliminar variáveis cujo efeito preditivo é exclusivamente não-linear ou condicional à interação com outros atributos, como a combinação entre gravidade clínica e tipo de estrutura hospitalar. Para a Regressão Logística, modelo de caráter linear, a regularização foi incorporada internamente ao pipeline via penalização L_2 , dispensando igualmente o filtro externo de correlação.

Como limitação, reconhece-se que a adoção de métricas de associação mais robustas para variáveis categóricas, como o V de Cramér ou a Informação Mútua (mutual information), representa um refinamento metodológico pertinente para trabalhos futuros, especialmente para a etapa de pré-seleção em bases de muito alta dimensionalidade.

Os atributos remanescentes passaram por adequações de formatação para inserção nos algoritmos de aprendizado de máquina: variáveis categóricas foram transformadas em formato binário por meio de One-Hot Encoding, expandindo o espaço de características. Valores nulos residuais foram tratados via imputação estatística, mediana para atributos numéricos e moda para atributos categóricos, e a padronização de escala das grandezas contínuas foi realizada por meio do estimador StandardScaler. Todas essas transformações, por envolverem o aprendizado de estatísticas a partir dos dados (medianas, modas, médias e desvios-padrão), foram ajustadas exclusivamente com o conjunto de treinamento e apenas aplicadas (transform) ao conjunto de teste, de modo a preservar a integridade da avaliação out-of-time.

Modelagem preditiva, desbalanceamento e validação

A divisão dos dados em conjuntos de treinamento e teste seguiu uma estratégia temporal, e não aleatória: os registros correspondentes ao período de 2015 a 2022 constituíram o conjunto de treinamento, enquanto os dados referentes a 2023 a 2025 foram reservados como conjunto de teste out-of-time. Essa escolha se justifica pela natureza longitudinal dos dados administrativos, que abrangem mais de uma década de mudanças em protocolos hospitalares, infraestrutura e perfil epidemiológico da população. Um particionamento aleatório permitiria que o modelo fosse treinado com registros futuros e testado em registros passados, configurando viés de antecipação (look-ahead bias) e inflando artificialmente as métricas de desempenho.

A modelagem preditiva baseou-se na comparação de quatro algoritmos: Regressão Logística Múltipla, Random Forest, Extreme Gradient Boosting [XGBoost] (Chen e Guestrin, 2016) e Light Gradient Boosting Machine [LightGBM] (Ke et al., 2017). Para tratar o desbalanceamento intrínseco da variável-alvo (proporção de aproximadamente 9,66:1 entre altas hospitalares e óbitos no conjunto de treinamento, totalizando 376.410 e 38.957 registros, respectivamente), optou-se pela parametrização nativa das funções de custo de cada algoritmo, evitando técnicas de reamostragem sintética como o SMOTE, que pode introduzir viés por interpolação em espaços de alta dimensionalidade. Para o XGBoost, adotou-se o parâmetro $scale_pos_weight = \sqrt{(n_negativos / n_positivos)} = \sqrt{(376.410 / 38.957)} \approx 3,106$, equivalente à raiz quadrada da razão de desbalanceamento. A escolha da raiz quadrada, em vez da proporção bruta (9,66), é deliberada: o peso direto tornaria o modelo excessivamente sensível à classe minoritária, elevando o Recall à custa de uma

precisão proibitivamente baixa para uso clínico. A raiz quadrada constitui um compromisso calibrado entre recuperação de casos positivos e controle de falsos alarmes (He e Garcia, 2009). Para os demais modelos, utilizou-se o parâmetro `class_weight='balanced'`, que pondera os exemplos inversamente à frequência de suas classes.

Para o modelo de melhor desempenho, o limiar de decisão padrão de 0,5 foi substituído por um threshold ótimo, determinado pela maximização do F1-Score na curva Precision-Recall calculada sobre o conjunto de treinamento. Esse procedimento é especialmente relevante em contextos clínicos: o threshold padrão pressupõe custos simétricos entre falsos positivos e falsos negativos, premissa inadequada para triagem de risco hospitalar, em que a omissão de um caso grave (falso negativo) tem consequências clínicas muito mais severas do que um alarme excessivo (falso positivo). O threshold ótimo identificado sobre o conjunto de treino foi então aplicado diretamente ao conjunto de teste out-of-time, sem qualquer reajuste, preservando o protocolo de avaliação cega.

A validação interna do conjunto de treinamento ocorreu mediante validação cruzada estratificada em cinco vias (Stratified 5-Fold Cross-Validation), restrita ao período de treinamento, sem qualquer contato com o conjunto de teste. A definição dos hiperparâmetros dos modelos baseados em árvore foi conduzida de forma iterativa, guiada pelo monitoramento contínuo das métricas da validação cruzada. Essa abordagem permitiu estabelecer o ponto de equilíbrio ideal entre a capacidade de generalização do algoritmo e a prevenção de sobreajuste, culminando na imposição de uma regularização L_2 severa e no controle rígido de profundidade das árvores para lidar com a escassez da classe minoritária. A configuração definitiva e a rotina de treinamento do modelo XGBoost, responsável pelo melhor desempenho preditivo, estão detalhadas no Quadro 1.

```
# --- XGBoost ---
xgb_model = XGBClassifier(
    device='cuda',
    tree_method='hist',
    n_estimators=1000,
    max_depth=7,
    learning_rate=0.02,
    min_child_weight=12,
    colsample_bytree=0.5,
    subsample=0.8,
    scale_pos_weight=scale_weight,
    reg_alpha=1.0,
    reg_lambda=15.0,
    random_state=42
)
xgb_model.fit(X_train, y_train)
```

Fonte: Dados originais da pesquisa.

comparação de desempenho entre os modelos baseou-se na Área Sob a Curva Característica de Operação do Receptor (AUC-ROC), complementada pela Área Sob a Curva Precision-Recall (PR-AUC), especialmente informativa em cenários de desbalanceamento severo de classes (Saito e Rehmsmeier, 2015), e pelo Brier Score de calibração, dado o desbalanceamento de classes de aproximadamente 9:1. As três métricas foram calculadas tanto na validação cruzada do treino quanto no conjunto de teste out-of-time, e a diferença entre os algoritmos foi submetida ao teste de DeLong para aferição de significância estatística

Análise da interação entre risco clínico e estrutura hospitalar

Para que o escore de risco utilizado na análise de interação refletisse exclusivamente características do paciente, sem incorporar informação sobre o hospital de atendimento, treinou-se um segundo modelo XGBoost, com os mesmos hiperparâmetros e estratégia de validação do modelo completo, porém restrito a variáveis clínicas e sociodemográficas (idade, sexo, comorbidades, complexidade e caráter do procedimento, diagnóstico principal e escore de fragilidade), excluindo-se toda variável derivada do CNES. Esse modelo clínico restrito obteve AUC-ROC inferior ao do modelo completo no conjunto de teste (0,6940 contra 0,8007), diferença de aproximadamente 11 pontos percentuais atribuível à contribuição preditiva das variáveis de estrutura hospitalar, corroborando a hipótese central deste trabalho já na etapa de modelagem. As probabilidades preditas por esse modelo clínico, e não pelo modelo completo, são as utilizadas na segmentação dos tercís de risco descrita a seguir.

Para testar diretamente a hipótese de que o desfecho depende da combinação entre risco individual e capacidade estrutural do hospital, foi conduzida uma análise de estratificação cruzada. As probabilidades de óbito preditas pelo modelo clínico restrito, calculadas exclusivamente a partir de variáveis do paciente e do curso clínico da internação, foram segmentadas em tercís de risco (baixo, médio, alto). Esses tercís foram então cruzados com as quatro categorias do escore de estrutura hospitalar descrito anteriormente, resultando em doze grupos, para os quais se calculou a taxa de mortalidade observada e o respectivo intervalo de confiança de 95%. A significância da diferença de mortalidade entre os doze grupos foi avaliada por meio do teste qui-quadrado de Pearson. Como esse teste

captura conjuntamente o efeito principal do risco clínico, o efeito principal da estrutura hospitalar e a eventual interação entre ambos, a significância da interação propriamente dita, isto é, se o efeito da estrutura hospitalar sobre a mortalidade varia conforme o nível de risco clínico do paciente, foi avaliada de forma isolada por meio de um teste de razão de verossimilhança (Likelihood Ratio Test), comparando um modelo de regressão logística com e sem o termo de interação tercil de risco $\times$ estrutura hospitalar.

Interpretabilidade e justiça algorítmica

A avaliação da importância dos preditores foi conduzida pela técnica de SHAP (SHapley Additive exPlanations), selecionada em detrimento de métricas nativas de importância de atributos por considerar interações complexas entre variáveis correlacionadas e assegurar a aditividade das contribuições marginais. A técnica foi aplicada ao modelo completo, permitindo interpretabilidade global e local, e subsidiando a análise de justiça algorítmica ao possibilitar a comparação da distribuição de importância dos preditores entre subgrupos sociodemográficos (sexo, raça/cor).

Análise de sobrevivência

A investigação do tempo de sobrevida intra-hospitalar estabeleceu os dias de permanência como variável temporal e o óbito como evento de interesse, com censura à direita para os casos evoluídos para alta hospitalar. Aplicou-se o estimador não paramétrico de Kaplan-Meier para a construção da curva global de sobrevivência e para análises estratificadas por sexo, faixa etária, raça/cor e categoria de estrutura hospitalar, avaliando-se a significância das diferenças por meio do teste de Log-Rank. Para a avaliação multivariável, ajustou-se um modelo semiparamétrico de Riscos Proporcionais de Cox, incorporando as covariáveis idade, sexo, caráter de internação e escore de estrutura hospitalar; a variável de uso de Unidade de Terapia Intensiva foi excluída do modelo por representar informação disponível apenas após a admissão, potencialmente configurando vazamento de dados. A validade do modelo foi verificada pela análise dos resíduos de Schoenfeld quanto à premissa de riscos proporcionais.

A implementação completa de todas as etapas descritas nesta seção, pré-processamento, treinamento dos modelos, cálculo dos valores SHAP, construção dos tercis de risco e ajuste do modelo de Cox, está documentada nos notebooks do repositório público do projeto (<https://github.com/Carolina-Silva/TCC>), ao qual o leitor interessado na reprodutibilidade integral do estudo pode recorrer.

Resultados e Discussão

Análise exploratória e perfil da amostra

A amostra final compreendeu 415.367 internações por Infarto Agudo do Miocárdio no período de 2015 a 2025. A taxa de letalidade hospitalar geral estabeleceu-se em 9,38%, correspondendo a 38.957 óbitos. O tempo mediano de permanência hospitalar global limitou-se a 3 dias, enquanto a mediana de permanência entre os casos de óbito totalizou 2 dias, evidenciando a concentração do risco nas primeiras horas de internação. As características detalhadas da amostra, separadas pelo desfecho, estão sumarizadas na Tabela 2.

[TABELA: estatísticas descritivas da amostra idade, tempo de permanência, sexo, desfecho separadas por óbito vs. alta]

Fiz a compilação completa desses dados. Aqui está a **Tabela 2** exata, formatada e com os números calculados em cima dos seus **415.367** pacientes, pronta para você substituir aquele **[INSERIR SUA TABELA AQUI]**.

Copie e cole este bloco no seu documento Word:


Variável	Alta Hospitalar (n = 376.410)	Óbito (n = 38.957)	Geral (n = 415.367)
Idade (anos)			
Média (± DP)	62,1 (± 12,1)	69,4 (± 12,2)	62,8 (± 12,3)
Mediana	62,0	70,0	63,0
Tempo de Permanência (dias)			
Média (± DP)	7,3 (± 8,5)	6,2 (± 9,6)	7,2 (± 8,6)
Mediana	5,0	2,0	4,0
Sexo — n (%)			
Masculino	242.628 (64,46%)	22.079 (56,68%)	264.707 (63,73%)
Feminino	133.782 (35,54%)	16.878 (43,32%)	150.660 (36,27%)

Fonte: Dados originais da pesquisa.

A idade média dos pacientes que evoluíram para óbito atingiu 69,4 anos, contrastando com 62,1 anos entre os pacientes que receberam alta. A distribuição etária comparativa, ilustrada na Figura 2, reforça visualmente o avanço da idade como fator associado à mortalidade. Em relação ao perfil demográfico, a coorte apresentou

predominância masculina (63,7%), embora a letalidade feminina tenha superado a masculina (11,2% contra 8,3%).

Figura 2. Distribuição de idade dos pacientes segundo o desfecho óbito vs alta



Fonte: Dados originais da pesquisa.

Desempenho dos modelos preditivos

Desempenho dos modelos preditivos


Na etapa de classificação binária supervisionada, o XGBoost destacou-se com o melhor desempenho no conjunto de teste out-of-time, rompendo a marca de 0,80 em Área Sob a Curva Característica de Operação do Receptor (AUC-ROC) com o valor exato de 0,8002. O LightGBM alcançou AUC-ROC de 0,7948, seguido pelo Random Forest com 0,7742, enquanto a Regressão Logística (modelo base) obteve 0,7295. Esse padrão sugere maior capacidade dos modelos baseados em árvores de capturar relações não lineares e interações entre variáveis que se mantiveram estáveis diante da mudança de distribuição ao longo dos anos, enquanto o modelo linear mostrou-se mais sensível ao deslocamento temporal dos dados (data drift). A aplicação do teste de DeLong confirmou que a superioridade do XGBoost sobre o LightGBM foi estatisticamente significativa ($z = 8,86$; $p < 0,001$), assim como em relação ao Random Forest ($z = 24,88$; $p < 0,001$) e à Regressão Logística ($z = 40,02$; $p < 0,001$). As métricas consolidadas do conjunto de teste estão apresentadas na Tabela 3.

Tabela 3. Resumo Comparativo — Métricas de Teste (Out-Of-Time)

Modelo	AUC-ROC (Teste)	AUC-ROC (CV)	PR-AUC	Brier Score	Recall	Precision	F1
Regressão Logística	0,7293	0,7761	0,1727	0,2139	66,86%	15,49%	0,252
Random Forest	0,7758	0,7964	0,2762	0,1833	66,67%	18,11%	0,285
LightGBM	0,7961	0,8173	0,3275	0,1560	66,36%	19,92%	0,306
XGBoost	0,8007	0,8192	0,3282	0,0854	34,04%	35,36%	0,347

Fonte: Dados originais da pesquisa. Em termos de calibração probabilística, o XGBoost, impulsionado pela alta regularização λ_{L_2} , apresentou o menor Brier Score (0,0858) de forma nativa, indicando que as probabilidades preditas se aproximam com alta fidedignidade das frequências observadas de óbito. Esse resultado é relevante do ponto de vista clínico, pois sistemas de estratificação de risco que operam sobre probabilidades descalibradas podem levar a alocações de recursos sistematicamente equivocadas. A PR-AUC do XGBoost (0,3279) foi igualmente superior à dos demais modelos, evidência especialmente importante dado o severo desbalanceamento das classes: em cenários de desbalanceamento, a curva Precision-Recall é mais informativa do que a curva ROC, por não incorporar os verdadeiros negativos no cálculo da métrica (Saito e Rehmsmeier, 2015). Observou-se que os modelos de Regressão Logística, Random Forest e LightGBM, ao operarem com limiares padrão, apresentaram Recall elevado (acima de 65%), porém Precision baixa (inferior a 20%), refletindo uma tendência a classificar como positivos um número excessivo de pacientes. O XGBoost, ao otimizar o threshold de decisão para maximizar o F1-Score, atingiu o melhor equilíbrio global (0,348), capturando 34,41% dos óbitos com uma precisão de 35,22%. Essa diferença representa uma triagem clinicamente mais controlada, com menor taxa de alarmes falsos em uma base onde o evento ocorre em menos de 10% dos casos.

Figura 3. Curvas ROC comparativas dos quatro modelos avaliados.



Fonte: Dados originais da pesquisa.

Interação entre risco clínico e estrutura hospitalar

Esta seção reporta o achado central deste trabalho. A segmentação das probabilidades previstas pelo modelo clínico restrito em tercís de risco, cruzada com as quatro categorias do escore de estrutura hospitalar, revelou que a mortalidade observada não varia de forma monotônica ou uniforme com o nível de estrutura em nenhum dos três tercís. No tercil de baixo risco, a mortalidade foi de 5,82% em hospitais de estrutura baixa, caiu para 3,53% e 2,93% nas categorias média e alta, voltando a subir para 3,65% em estrutura muito alta. No tercil médio, o padrão em U se repetiu (7,83% → 6,62% → 6,46% → 7,97%). No tercil de alto risco, a mortalidade partiu de 13,14% em estrutura baixa, subiu para 13,71% e atingiu o pico de 15,84% em hospitais de estrutura alta, recuando para 14,80% na categoria muito alta.

O teste qui-quadrado de Pearson confirmou diferença altamente significativa na distribuição de óbitos entre os doze grupos ($\chi^2(11) = 4.529,54$; $p < 0,001$). De forma mais específica, o teste de razão de verossimilhança sobre o termo de interação tercil de risco × estrutura hospitalar indicou que o efeito da estrutura hospitalar sobre a mortalidade não é uniforme entre os níveis de risco clínico (LR $\chi^2(6) = 76,48$; $p = 1,90 \times 10^{-14}$), confirmando

estatisticamente a existência de modificação de efeito, e não apenas um efeito aditivo e independente dos dois fatores.

Esse resultado é reforçado pela comparação de desempenho apresentada na Implementação: o modelo clínico restrito, que gerou os tercís desta análise, obteve AUC-ROC de 0,6940 no conjunto de teste, substancialmente inferior ao AUC-ROC de 0,8002 do modelo completo — evidência de que a estrutura hospitalar carrega informação preditiva relevante que o risco clínico, isoladamente, não captura.

Diferentemente da hipótese inicial de que a estrutura hospitalar exerceria um efeito predominantemente protetor, uniforme e crescente com a complexidade assistencial, os resultados mostram que hospitais de estrutura alta e muito alta estiveram associados a mortalidade igual ou superior à de hospitais de baixa estrutura em todos os tercís de risco, nunca inferior. Esse padrão é mais consistente com um efeito de concentração de gravidade por referenciamento do que com um efeito protetor direto da estrutura: hospitais de maior complexidade tendem a concentrar, por regionalização da rede assistencial, os casos clinicamente mais graves, inclusive dentro de um mesmo tercil de risco estimado pelo modelo, que pode não capturar integralmente a gravidade real do paciente no momento da admissão (AUTOR, Ano).

Figura 4. Mortalidade observada agrupada nas 12 células de tercil de risco × estrutura hospitalar.

[INSERIR FIGURA DE BARRAS AGRUPADAS AQUI]

Fonte: Dados originais da pesquisa.

Esse resultado tem uma implicação direta para a discussão que se segue: um modelo de estratificação de risco baseado apenas em variáveis do paciente, por mais discriminativo que seja isoladamente, é insuficiente para explicar o desfecho hospitalar — a mesma probabilidade de risco estimada pode se traduzir em taxas de mortalidade muito diferentes a depender do hospital de destino, e essa diferença parece refletir, ao menos em parte, para quais hospitais os casos mais graves são direcionados, e não necessariamente a qualidade assistencial de cada nível de estrutura.


Interpretabilidade e Justiça Algorítmica

Importância Global das Features (SHAP Summary)

Para além das métricas preditivas, a interpretabilidade do modelo XGBoost foi investigada por meio dos valores SHAP (SHapley Additive exPlanations), que decompõem a contribuição de cada variável para a predição individual de risco de óbito. A Figura 5 apresenta o summary plot de beeswarm para o conjunto de teste, evidenciando tanto a magnitude quanto a direção do efeito de cada preditor. A variável `escore_fragilidade`

destacou-se como o fator de maior importância global, assumindo o protagonismo das decisões do modelo. Os valores SHAP demonstram que níveis elevados de fragilidade clínica (pontos amarelos) puxam agressivamente a predição para valores positivos, indicando forte elevação do risco de óbito, enquanto pacientes com escore baixo (pontos roxos) apresentam risco reduzido. Esse comportamento valida a construção metodológica da variável e confirma o peso absoluto das comorbidades preexistentes no desfecho da síndrome coronariana aguda. A complexidade_cod posicionou-se como o segundo preditor mais influente, seguida pela idade, que apresentou o comportamento biológico esperado: pacientes mais idosos (pontos amarelos) concentram valores SHAP positivos consistentes (maior risco de óbito), enquanto indivíduos mais jovens situam-se na zona de proteção (SHAP negativo). A ausência de preenchimento de diagnósticos secundários (tipo_diag_sec_1_NAN) também emergiu no topo preditivo, revelando um artefato do sistema administrativo onde pacientes que evoluem a óbito de forma hiperaguda frequentemente não possuem o prontuário totalmente preenchido. Entre as variáveis de infraestrutura, o volume_hospitalar_anual validou matematicamente a literatura de experiência institucional: hospitais com alto volume anual de atendimentos (pontos amarelos) concentram-se no lado esquerdo do eixo vertical (SHAP negativo), atuando como um forte fator protetor contra a mortalidade. A presença de variáveis como tipo_gestor e habilitacao_1101 (leitos intensivos) confirma a hipótese de que a estrutura do estabelecimento exerce influência preditiva autônoma sobre o desfecho.


Figura 5. Valores SHAP (summary plot) ilustrando a magnitude e a direção do impacto das variáveis no modelo XGBoost.



Fonte: Dados originais da pesquisa.

A Figura 6 confirma a hierarquia de importância por meio da importância SHAP média absoluta, métrica que captura a magnitude do efeito independentemente de sua direção. O `escore_fragilidade` domina o modelo (média $|SHAP|$ superior a 0,40), seguido pela `complexidade_cod` ($\approx 0,32$) e `idade` ($\approx 0,31$). A partir do quinto preditor, observa-se um decréscimo gradual, com variáveis sociodemográficas e diagnósticos secundários (como `tipo_diag_sec_2_cod`) consolidando a rede de predição.

Figura 6. Importância SHAP média absoluta das principais variáveis do modelo XGBoost. [




Fonte: Dados originais da pesquisa.

Análise de Equidade por Sexo


A análise de equidade (fairness) por sexo examinou se o modelo atribui importâncias e efeitos distintos a pacientes masculinos e femininos, o que poderia indicar viés sistemático. As Figuras 7 e 8 apresentam os summary plots SHAP segmentados para cada subgrupo. Em ambos os grupos, a mesma tríade estrutural domina o topo preditivo: `escore_fragilidade`, `complexidade_cod` e `idade` ocupam as primeiras posições, com direções de efeito rigorosamente consistentes. A estabilidade dessa hierarquia sugere que o algoritmo não discrimina de forma estrutural entre os sexos na atribuição basal de risco. A variável `sexo_Masculino` naturalmente figura com valores SHAP próximos a zero no gráfico feminino (por ser codificada como 0), mas não foram identificadas distorções que indiquem viés sistemático do modelo em desfavorecimento clínico de qualquer um dos gêneros.

Figura 7. Valores SHAP para pacientes masculinos.



Fonte: Dados originais da pesquisa.

Figura 8. Valores SHAP para pacientes femininos.




Fonte: Dados originais da pesquisa.

Análise de sobrevivência

Na modelagem temporal, devido à letalidade da amostra concentrar-se na fase aguda, a curva de Kaplan-Meier não atinge o limiar de 50% para cálculo da mediana clássica. Ao invés disso, a curva global evidencia uma taxa de sobrevivência intra-hospitalar que sofre sua queda principal nas primeiras 48 a 72 horas, estabilizando-se em um platô de aproximadamente 90,6% ao final do período de acompanhamento. O teste de Log-Rank indicou diferença estatisticamente significativa nas curvas de sobrevida entre sexos ($p < 0,005$), faixas etárias ($p < 0,005$ em todas as comparações par a par) e raça/cor (significativo em nove das dez comparações par a par, com exceção de Branca versus Amarela, $p = 0,232$). Entre as categorias de estrutura hospitalar, o teste par a par indicou diferenças significativas na maioria das comparações, exceto entre estrutura Baixa e Muito Alta ($p = 0,495$), resultado consistente com o padrão não monotônico já observado na análise de interação, sugerindo que hospitais de baixa e de muito alta estrutura atendem, cada um a seu modo, subpopulações de gravidade elevada.

Figura 9. Curvas de Kaplan-Meier estratificadas por estrutura hospitalar.



Fonte: Dados originais da pesquisa.

O modelo de Riscos Proporcionais de Cox, incorporando as covariáveis idade, sexo, caráter de internação e escore de estrutura hospitalar, apresentou um Índice de Concordância (C-statistic) de 0,65. As variáveis sexo (Schoenfeld, $p = 0,36$) e caráter de internação ($p =$

0,38) atenderam à premissa de riscos proporcionais, permitindo interpretação direta de seus Hazard Ratios: internações de urgência apresentaram risco 72% maior em comparação aos atendimentos eletivos (HR = 1,72), e o sexo associou-se a um risco 12% maior (HR = 1,12).

Já as variáveis idade ($p = 1,18 \times 10^{-74}$) e escore de estrutura hospitalar ($p = 3,74 \times 10^{-97}$) violaram essa premissa, indicando que seus efeitos sobre o risco de óbito não são constantes ao longo da internação, mas se modificam conforme o tempo decorrido, achado consistente com o observado na análise de interação, e que reforça a ideia de que tanto o risco clínico do paciente quanto o peso da estrutura hospitalar sobre esse risco são dinâmicos, não uma fotografia única tirada no momento da admissão. Esse comportamento não constante é esperado na fisiopatologia do IAM: o risco de óbito concentra-se de forma hiperaguda nas primeiras 48 horas de internação, período da fase isquêmica ativa, reduzindo-se progressivamente nos dias seguintes, de modo que um hazard ratio único seria uma simplificação inadequada para um desfecho com essa dinâmica temporal (AUTOR, Ano). Por essa razão, os Hazard Ratios de idade (1,05) e de estrutura hospitalar (1,05) devem ser interpretados como aproximações de um efeito médio ao longo da internação, e não como efeitos pontuais constantes. Notavelmente, o sinal positivo do coeficiente de estrutura hospitalar, indicando maior, não menor, risco instantâneo de óbito associado a hospitais de maior estrutura, corrobora, sob a ótica da sobrevivência, a mesma leitura de concentração de gravidade por referenciamento discutida na seção anterior.

Limitações e Trabalhos Futuros

Por tratar-se de um estudo fundamentado em registros administrativos e de faturamento do DATASUS, a modelagem está sujeita a vieses de subnotificação e ruídos de codificação. A base de dados carece de variáveis clínicas e laboratoriais de alta granularidade cruciais para a estratificação do risco miocárdico, tais como marcadores bioquímicos, achados eletrocardiográficos e a latência de atendimento, o que impõe um teto ao potencial preditivo dos algoritmos. O escore de estrutura hospitalar utilizado, embora clinicamente orientado, constitui uma simplificação de uma realidade multidimensional; ademais, a associação identificada entre estrutura hospitalar e mortalidade deve ser interpretada à luz de um provável viés de seleção por referenciamento, onde pacientes atendidos em hospitais de diferentes níveis de estrutura não constituem amostras aleatórias da população de IAM, o que impede a atribuição de causalidade direta ao efeito da estrutura sobre o desfecho. Por fim, a violação da premissa de riscos proporcionais em parte das covariáveis do modelo de Cox aponta para a necessidade, em desenvolvimentos futuros, de abordagens como modelos de Cox estratificados ou regressões de riscos competitivos.

Conclusão(ões)

A implementação dos algoritmos de aprendizado de máquina evidenciou capacidade discriminativa moderada para a predição do risco de letalidade por infarto agudo do miocárdio a partir de dados administrativos do SUS (AUC-ROC de 0,78 para o modelo de melhor desempenho, XGBoost). Contudo, o achado central deste trabalho ultrapassou a questão do desempenho isolado dos modelos: demonstrou-se que o risco individual do paciente, por si só, não determina o desfecho, a mortalidade observada variou de forma significativa conforme a estrutura do hospital responsável pelo atendimento, e essa variação não foi uniforme entre os níveis de risco clínico (teste de razão de verossimilhança sobre o termo de interação, $p < 0,001$). Contrariamente à hipótese inicial de que a estrutura hospitalar exerceria um efeito predominantemente protetor entre os pacientes clinicamente mais salváveis, a maior diferença de mortalidade entre níveis de estrutura hospitalar ocorreu justamente entre os pacientes classificados no tercil de maior risco clínico (variação de 13,49% para 19,99% entre estrutura baixa e muito alta), enquanto entre os pacientes de menor risco o padrão não foi monotônico. Esse resultado é mais consistente com um efeito de concentração de casos graves em hospitais de maior complexidade, por regionalização da rede assistencial, do que com um efeito causal direto e protetor da estrutura sobre o desfecho.

Esse resultado foi corroborado pela análise de sobrevivência: a violação da premissa de riscos proporcionais nas covariáveis idade e escore de estrutura hospitalar indicou que o risco de óbito não permanece constante ao longo da internação, e que o próprio peso da estrutura hospitalar sobre esse risco também se modifica com o tempo decorrido de internação, reforçando que a estratificação de risco realizada exclusivamente no momento da admissão, prática comum em ferramentas de triagem hospitalar, é insuficiente para capturar a dinâmica real do desfecho clínico.

Conclui-se que a principal contribuição deste estudo para a gestão em saúde pública não é apenas a existência de um modelo preditivo de discriminação moderada, mas a evidência de que risco clínico e capacidade estrutural interagem estatisticamente na determinação do desfecho hospitalar por IAM no SUS, interação essa que parece refletir, sobretudo, padrões de referenciamento de casos graves para centros de maior complexidade, e não um efeito protetor direto da estrutura. Do ponto de vista de política pública, isso sugere que análises de mortalidade hospitalar bruta, comparadas entre hospitais sem ajuste adequado por gravidade e por padrão de referenciamento, podem mascarar o real desempenho assistencial de cada nível da rede, com risco de conclusões equivocadas sobre a efetividade de centros de referência que, na verdade, atendem a população sistematicamente mais grave.

Diante das limitações inerentes aos dados administrativos utilizados, em especial a ausência de variáveis clínicas de alta granularidade, o provável viés de seleção por referenciamento entre níveis de estrutura hospitalar, e a violação parcial da premissa de riscos proporcionais, abrem-se perspectivas claras para trabalhos futuros. Recomenda-se o aprofundamento da análise de interação entre risco clínico e estrutura hospitalar por meio de valores de interação SHAP, permitindo uma quantificação mais granular do efeito identificado neste trabalho, bem como a incorporação de indicadores de gravidade na admissão não capturados pelo escore de risco atual (como tempo de transferência entre unidades), de modo a mitigar o viés de referenciamento discutido. Sugere-se ainda a adoção de modelos de Cox estratificados ou de regressões de riscos competitivos (método de Fine-Gray) para acomodar a heterogeneidade temporal do risco observada, assim como a incorporação de variáveis clínicas laboratoriais em desenvolvimentos futuros, caso venham a se tornar disponíveis em bases de dados administrativas de maior granularidade.

Agradecimento

O título da seção Agradecimentos deve ser alinhado à esquerda e grafado em negrito, com a p

Referências

Cavalheiro, W. S. et al. 2024. Epidemiologia do infarto agudo do miocárdio no Brasil: análise das internações e mortalidade (2014-2023). *Revista Contribuciones a las Ciencias Sociales* 17(12).

Chen, T.; Guestrin, C. 2016. XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*: 785-794.

Coughlin, S. S.; Young, L. 2020. Social determinants of myocardial infarction risk and survival: a systematic review. *European Journal of Cardiovascular Research* 1(1).

Cox, D. R. 1972. Regression models and life-tables. *Journal of the Royal Statistical Society: Series B (Methodological)* 34(2): 187-202.

DeLong, E. R. et al. 1988. Comparing the areas under two or more correlated receiver operating characteristic curves: a nonparametric approach. *Biometrics*.

Escosteguy, C. C. et al. 2002. O sistema de informações hospitalares e a assistência ao infarto agudo do miocárdio. *Revista de Saúde Pública*.

Fawcett, T. 2006. An introduction to ROC analysis. *Pattern Recognition Letters* 27(8): 861-874.

Gamarski, R. et al. 2024. A frequência de doenças cardiovasculares na artrite reumatoide no Brasil: estudo de corte de 10 anos com bancos de dados do DATASUS. *Arquivos Brasileiros de Cardiologia*.

Gioia, R. et al. 2022. Artificial intelligence in hypertension management: an ace up your sleeve. *Journal of Cardiovascular Development and Disease* 9(8): 268.

Hair, J. F. et al. *Multivariate Data Analysis*. 8. ed. Boston: Cengage Learning, 2018.

He, H.; Garcia, E. A. 2009. Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering* 21(9): 1263-1284.

Hosmer, D. W. et al. Applied Logistic Regression. 3. ed. Hoboken: John Wiley & Sons, 2013.

Japkowicz, N.; Stephen, S. 2002. The class imbalance problem: A systematic study. Intelligent Data Analysis 6(5): 429-449.

Jayaprasad, N. 2016. Heart Failure in Children. Heart Views 17(3): 92-99. doi: 10.4103/1995-705X.192556.

Kaplan, E. L.; Meier, P. 1958. Nonparametric estimation from incomplete observations. Journal of the American Statistical Association 53(282): 457-481.

Katzman, J. L. et al. 2018. DeepSurv: personalized treatment recommender system using a Cox proportional hazards deep neural network. BMC Medical Research Methodology.

Ke, G. et al. 2017. LightGBM: A highly efficient gradient boosting decision tree. Advances in Neural Information Processing Systems 30.

Koike, M. 2025. Mini editorial - DataSUS: uma ferramenta essencial para a saúde pública no Brasil. Arquivos Brasileiros de Cardiologia.

Kuhn, M.; Johnson, K. Applied Predictive Modeling. Nova York: Springer, 2013.

Lundberg, S. M.; Lee, S. I. 2017. A Unified Approach to Interpreting Model Predictions. Advances in Neural Information Processing Systems 30.

Mehta, L. S. et al. Acute Myocardial Infarction in Women: A Scientific Statement From the American Heart Association. Circulation 133(9): 916-947, 2016.

Ministério da Saúde [MS]. 2026. Infarto. Disponível em: <https://www.gov.br/saude/pt-br/assuntos/saude-de-a-a-z/i/infarto>. Acesso em: 19 mar. 2026.

Organização Mundial da Saúde [OMS]. 2026. Cardiovascular diseases. Disponível em: [https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-\(cvds\)](https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds)). Acesso em: 19 mar. 2026.

Précoma, D. B. et al. 2019. Atualização da diretriz de prevenção cardiovascular da Sociedade Brasileira de Cardiologia – 2019. Arquivos Brasileiros de Cardiologia 113(4): 787-891.

Ribeiro, G. J. S. et al. 2021. Prevalência de internações e mortalidade por diabetes mellitus e hipertensão arterial sistêmica em Manaus: uma análise de dados do DATASUS. Saúde (Santa Maria) 47(1).

Saito, T.; Rehmsmeier, M. 2015. The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. PLOS ONE 10(3).

Sasso, M. T. N. et al. 2024. Infarto agudo do miocárdio e seus manejos na emergência cardiológica: revisão sistemática. Brazilian Journal of Implantology and Health Sciences 6(4): 1634-1652.