

Predição de Letalidade Hospitalar por Infarto Agudo do Miocárdio no SUS

Carolina Nascimento Silva^{1*}; Maíra Blumer Fatoresso²

^{1*} MBA em Ciência de Dados e Analytics, USP/ESALQ. E-mail autor correspondente:
nascimento.carolina202@gmail.com

² Doutora em Estatística pela Universidade de São Paulo (USP).

Predição de Letalidade Hospitalar por Infarto Agudo do Miocárdio no SUS

Resumo

O infarto agudo do miocárdio caracteriza-se pela alta letalidade no sistema público brasileiro, cujo desfecho é determinado não apenas por fatores clínicos individuais, mas também pela capacidade estrutural do hospital responsável pelo atendimento. Este trabalho teve como objetivo investigar se, e de que forma, o risco de letalidade hospitalar por infarto agudo do miocárdio é modulado pela estrutura hospitalar e pelo tempo de internação, no estado de São Paulo, no período de 2015 a 2025. Para tanto, realizou-se a integração de bases de dados secundários do DATASUS, unificando registros clínicos do Sistema de Informações Hospitalares e variáveis de infraestrutura do Cadastro Nacional de Estabelecimentos de Saúde, vinculadas mensalmente a cada internação. Implementaram-se algoritmos supervisionados de aprendizado de máquina (Regressão Logística Múltipla, Random Forest, XGBoost e LightGBM) para a construção de um escore de risco individual, cujas probabilidades preditas foram segmentadas em tercís e cruzadas com um escore de estrutura hospitalar derivado do CNES. O modelo XGBoost obteve o melhor desempenho no conjunto de teste temporal (AUC-ROC = 0,78). A análise de interação revelou que o efeito da estrutura hospitalar sobre a mortalidade não foi uniforme entre os níveis de risco clínico (teste de razão de verossimilhança, $p < 0,001$), com a maior disparidade observada entre pacientes de alto risco (13,5% de óbitos em hospitais de baixa estrutura contra 20,0% em hospitais de estrutura muito alta). A Análise de Sobrevida, por meio do modelo de Riscos Proporcionais de Cox, confirmou que o efeito da estrutura hospitalar sobre o risco de óbito não permanece constante ao longo da internação (violação da premissa de riscos proporcionais, $p < 0,001$). Concluiu-se que a estratificação de risco baseada exclusivamente em variáveis do paciente é insuficiente para explicar o desfecho hospitalar, e que a associação entre estrutura hospitalar e mortalidade, mais acentuada entre os pacientes de maior gravidade, é consistente com um padrão de concentração de casos complexos em centros de maior complexidade assistencial, e não com um efeito protetor direto da estrutura sobre o risco individual.

Palavras-chave: Inteligência Artificial; Saúde Pública; Análise de Sobrevida; Modelagem Preditiva; Iniquidade Estrutural em Saúde; DATASUS.

Prediction of Hospital Lethality by Acute Myocardial Infarction in the Public Health System

Abstract

Acute myocardial infarction is associated with high hospital lethality in the Brazilian public health system, with outcomes determined not only by individual clinical factors but also by the structural capacity of the hospital providing care. This study aimed to investigate whether and how the risk of in-hospital mortality from acute myocardial infarction is associated with hospital structure and length of stay in the state of São Paulo, Brazil, from 2015 to 2025. Secondary data from DATASUS were integrated by combining clinical records from the Hospital Information System with hospital infrastructure variables from the National Registry of Health Establishments (CNES), linked monthly to each hospitalization. Supervised machine learning algorithms, Multiple Logistic Regression, Random Forest, XGBoost, and LightGBM, were implemented to construct an individual risk score. Predicted probabilities were divided into tertiles and cross-referenced with a hospital structure score derived from CNES data. XGBoost achieved the best performance on the temporal test set (ROC-AUC = 0.78). Interaction analysis showed that the association between hospital structure and mortality was not uniform across clinical risk levels (likelihood ratio test, $p < 0.001$), with the greatest disparity observed among high-risk patients (13.5% mortality in hospitals with low structural capacity versus 20.0% in hospitals with very high structural capacity). Survival analysis using the Cox proportional hazards model confirmed that the effect of hospital

structure on the risk of death was not constant throughout hospitalization (violation of the proportional hazards assumption, $p < 0.001$). These findings indicate that risk stratification based exclusively on patient-level variables is insufficient to explain hospital outcomes. The stronger association between hospital structure and mortality among patients at higher risk is consistent with a pattern of concentration of complex cases in centers with greater care complexity, rather than a direct protective effect of hospital structure on individual mortality risk.

Keywords trt

Considerações Iniciais

Segundo dados da Organização Mundial da Saúde (2025), as doenças cardiovasculares foram responsáveis por aproximadamente 17 milhões de mortes ao redor do globo anualmente. Dentre essas enfermidades, destacou-se o infarto agudo do miocárdio [IAM], que, somado aos acidentes vasculares cerebrais, respondeu por quatro em cada cinco mortes por doenças cardíacas. No cenário nacional, estimou-se a ocorrência de 300 mil a 400 mil casos de IAM anualmente, dos quais aproximadamente cinco em cada sete evoluíram para óbito, conforme dados do Ministério da Saúde (2025). Além da perda de vidas, o infarto impõe grande impacto financeiro e estrutural ao sistema público de saúde, em razão do alto custo de internações e procedimentos de alta complexidade, além de acarretar sequelas que reduzem a qualidade de vida dos sobreviventes (Sasso et al., 2024).

Fatores fisiológicos e clínicos, como diabetes e hipertensão, somados a fatores comportamentais, como sedentarismo e altos níveis de estresse, são amplamente documentados na literatura como causas de maior risco cardiovascular (Ribeiro et al., 2021; Précoma et al., 2019). Contudo, a sobrevivência ao IAM ultrapassou as questões fundamentais do paciente: fatores estruturais, relacionados à infraestrutura hospitalar, mostraram-se determinantes críticos para o desfecho, a ponto de a literatura já apontar que um mesmo perfil clínico pode resultar em desfechos distintos a depender da capacidade assistencial do hospital de atendimento (Escosteguy et al., 2002; Cavalheiro et al., 2024). Essa constatação sugere que a estratificação de risco centrada exclusivamente no paciente, ainda que amplamente adotada, captura apenas parte da explicação sobre a letalidade hospitalar por IAM.

Com o avanço da tecnologia, a integração de algoritmos de aprendizado de máquina e métodos de Ciência de Dados demonstrou potencial crescente no suporte à estratificação de risco de pacientes com patologias cardiovasculares, permitindo a identificação de padrões em grandes volumes de dados e subsidiando o desenvolvimento de modelos preditivos capazes de auxiliar na formulação de políticas públicas (Koike, 2025; Gioia et al., 2022). No cenário nacional, o Departamento de Informática do Sistema Único de Saúde [DATASUS] disponibiliza bases de dados que integram informações sobre morbimortalidade, internações hospitalares e infraestrutura de saúde, cuja relevância reside na possibilidade de análises que unam variáveis clínicas, demográficas e estruturais em uma mesma base analítica.

Ainda assim, apesar da relevância dessas bases e do crescente número de estudos voltados à modelagem preditiva em saúde cardiovascular (Koike, 2025), permanecem limitadas as pesquisas que investigam como o efeito de fatores estruturais sobre a mortalidade se modifica conforme o nível de risco clínico do paciente, indo além de análises que tomam ambos os fatores de forma isolada (como observado em Escosteguy et al.,

2002). Da mesma forma, a literatura nacional fortemente caracterizada por análises epidemiológicas descritivas e estáticas sobre o desfecho de óbito na alta hospitalar (e.g., Cavalheiro et al., 2024) ainda carece de investigações que integrem diferentes sistemas de informação do SUS para avaliar a variação do risco de óbito de forma dinâmica ao longo do próprio período de internação. Essa lacuna limita a compreensão sobre como desigualdades estruturais influenciam os desfechos clínicos de forma contínua, e não apenas como uma condição fixa observada na admissão.

Diante do cenário exposto, este trabalho teve como objetivo investigar se, e de que forma, o risco de letalidade hospitalar por IAM no Sistema Único de Saúde é modulado pela estrutura hospitalar e pelo tempo de internação. Para tal, propôs-se a integração dos dados de desfechos clínicos do Sistema de Informações Hospitalares [SIH] às variáveis de infraestrutura do Cadastro Nacional de Estabelecimentos de Saúde [CNES], referentes ao estado de São Paulo, no período de 2015 a 2025. Especificamente, buscou-se: (i) construir e comparar modelos supervisionados de aprendizado de máquina capazes de estimar o risco individual de óbito hospitalar; (ii) investigar se o efeito da estrutura hospitalar sobre a mortalidade observada varia conforme o nível de risco clínico do paciente; e (iii) aplicar a análise de sobrevivência para avaliar se e como o risco de óbito se modifica ao longo do tempo de permanência hospitalar.

Para atingir tais objetivos, foram implementados algoritmos de aprendizado de máquina para fins de análise supervisionada, utilizando-se a Regressão Logística Múltipla com penalização de classes como modelo de referência, contraposta a métodos avançados baseados em árvores de decisão com Gradient Boosting, o Extreme Gradient Boosting (XGBoost), o Light Gradient Boosting Machine (LightGBM) e o Random Forest. O desempenho preditivo dos modelos foi avaliado de forma abrangente: além da Área Sob a Curva ROC (AUC-ROC), foram reportadas a Área Sob a Curva Precision-Recall (PR-AUC), especialmente informativa em cenários de desbalanceamento severo de classes (Saito e Rehmsmeier, 2015), e a calibração de probabilidades mensurada pelo Brier Score. A interpretabilidade dos preditores gerados foi obtida pela adoção de valores SHapley Additive exPlanations (SHAP), utilizados tanto para identificar os principais determinantes do risco quanto para subsidiar a análise de justiça algorítmica das predições. Para a modelagem temporal, aplicou-se o modelo semiparamétrico de Riscos Proporcionais de Cox, complementado pelo estimador de Kaplan-Meier.

Por fim, cabe destacar as limitações inerentes ao método proposto. A precisão dos modelos preditivos encontra-se condicionada à qualidade da coleta e do preenchimento originais das bases secundárias do DATASUS, estando o conjunto de dados sujeito a potenciais subnotificações, ruídos de codificação administrativa e à ausência de variáveis de evolução clínica laboratorial intra-hospitalar. Da mesma forma, o indicador de estrutura

hospitalar utilizado, embora clinicamente orientado, constitui uma simplificação de uma realidade multidimensional. Portanto, o tratamento rigoroso dos dados e a atenção às escolhas metodológicas visaram mitigar tais distorções, promovendo inferências úteis para o planejamento de políticas públicas.

Implementação de Algoritmo(s) de Machine Learning

A presente pesquisa caracterizou-se como um estudo quantitativo e aplicado, fundamentado em dados secundários de acesso público. A metodologia adotada partiu de um levantamento de registros administrativos do Sistema Único de Saúde e teve como delineamento principal a implementação e comparação de algoritmos de aprendizado de máquina voltados à predição de risco de óbito hospitalar por Infarto Agudo do Miocárdio, complementada pela investigação de como esse risco é modulado pela estrutura hospitalar e pelo tempo de internação.

[FIGURA: diagrama de fluxo do pipeline DATASUS FTP → conversão .dbc/.csv → tradução de códigos → limpeza SIH → integração CNES (chave hospital×mês) → seleção de features → split temporal → modelagem/SHAP → análise de interação → sobrevivência.]

Descrição das bases de dados

Foram utilizadas duas bases de dados públicas mantidas pelo Departamento de Informática do Sistema Único de Saúde, acessadas via protocolo de transferência de arquivos [FTP]. A primeira base utilizada foi o Sistema de Informações Hospitalares [SIH], que registra as internações hospitalares financiadas pelo SUS por meio das Autorizações de Internação Hospitalar, cada registro corresponde a uma internação e contém informações clínicas, sociodemográficas e administrativas do paciente. Foram coletados os registros referentes a todos os meses do período compreendido entre 2015 e 2025, no estado de São Paulo, totalizando 28.284.570 internações em formato bruto.

A segunda base utilizada foi o Cadastro Nacional de Estabelecimentos de Saúde [CNES], registro oficial que documenta a infraestrutura das unidades de saúde no Brasil. Diferentemente de uma abordagem de corte único, empregou-se aqui a granularidade mensal do CNES, ou seja, uma fotografia da infraestrutura hospitalar para cada combinação de estabelecimento e mês de competência, o que permitiu vincular cada internação à condição estrutural real do hospital no momento exato de sua ocorrência, e não a um retrato posterior ou anterior do estabelecimento. Foram utilizadas cinco tabelas do CNES (Estabelecimentos, Leitos, Equipamentos, Serviços Especializados e Habilitações), descritas na Tabela 1.

Tabela 1. Descrição das tabelas do Cadastro Nacional de Estabelecimentos de Saúde

Tabela	Sigla	Conteúdo	Registros
Estabelecimentos	ST	Dados cadastrais principais de cada hospital	62.522
Equipamentos	EQ	Equipamentos existentes e em uso	552.840
Habilitações	HB	Habilitações e certificações do estabelecimento	1.471.830
Leitos	LT	Quantidade de leitos por tipo (clínico, cirúrgico, Unidade de Terapia Intensiva)	2.213.516
Serviços Especializados	SR	Serviços ofertados pelo estabelecimento	427.109

Extração, integração e tratamento dos dados

Todo o ciclo de extração, transformação e carga foi operacionalizado em linguagem Python (versão 3.11). Os arquivos brutos, disponibilizados em formato .dbc (formato proprietário comprimido do DATASUS), foram descomprimidos e convertidos para o formato .csv. Em razão de o DATASUS armazenar variáveis categóricas como códigos numéricos sem significado direto (por exemplo, sexo ou raça/cor codificados como dígitos), foi implementado um motor de tradução baseado nos dicionários oficiais da plataforma (arquivos .def e .cnv), convertendo os códigos em descrições legíveis.

Adicionalmente aos dicionários institucionais do DATASUS, foi realizada uma etapa complementar de tradução semântica das variáveis codificadas que compõem o espaço preditivo do modelo. Os códigos de procedimentos hospitalares foram mapeados à tabela oficial do Sistema de Gerenciamento da Tabela de Procedimentos, Medicamentos e OPM do SUS (SIGTAP), convertendo, por exemplo, o código 406030049 para "Angioplastia com Stent" e o código 406030030 para "Angioplastia com 2 Stents". Os diagnósticos secundários foram traduzidos conforme a Classificação Internacional de Doenças, 10ª revisão (CID-10), com códigos como I25 interpretados como "Doença Isquêmica Crônica" e I50 como "Insuficiência Cardíaca". As variáveis de infraestrutura do CNES receberam nomenclaturas descritivas referentes às habilitações e serviços registrados, por exemplo, habilitacao_802 foi renomeada para "Habilitação Alta Complexidade em Cardiologia". Essa etapa visa diretamente à interpretabilidade dos gráficos de importância SHAP, garantindo que as contribuições de cada variável sejam legíveis e clinicamente contextualizadas no relatório de resultados.

O tratamento de dados ausentes seguiu um critério uniforme entre as duas bases: colunas com [Critério de corte bem fundamentado na literatura (Kuhn & Johnson; Hair et al.).] proporção de valores ausentes superior a 70% foram removidas, por se considerar que a imputação de variáveis com densidade informacional inferior a 30% comprometeria a validade científica do modelo (Kuhn e Johnson, 2013; Hair et al., 2018). Foram selecionadas para análise apenas as internações cujo diagnóstico principal correspondia ao Infarto Agudo do Miocárdio, identificado pelo prefixo I21 da Classificação Internacional de Doenças, 10ª revisão [CID-10]. Das 28.284.570 internações brutas do SIH, 416,027 corresponderam a esse critério, representando 1.47% do total. Foram adicionalmente excluídos 660 registros de pacientes com idade inferior a 18 anos, por se tratar de evento biologicamente distinto do IAM aterosclerótico adulto, frequentemente associado a cardiopatias congênitas (Jayaprasad, 2016), resultando em uma base de 415.367 internações de adultos.

A integração entre as bases SIH e CNES foi realizada por meio de uma chave composta pelo código CNES do estabelecimento e a competência temporal (ano-mês), o que garantiu que a infraestrutura atribuída a cada internação refletisse o mês exato de ocorrência da admissão, eliminando o vazamento temporal que ocorreria caso um único retrato da infraestrutura hospitalar fosse aplicado indistintamente a internações ocorridas em anos diferentes.

```
# Criando a chave de competência (YYYYMM) no SIH para coincidir com chave do CNES
df_sih['competencia']=df_sih['ano_competencia']+df_sih['mes_competencia']

# Garantindo que os tipos das chaves sejam idênticos em ambas as bases
df_sih['codigo_cnes']= df_sih['codigo_cnes'].astype(str).str.strip().str.zfill(7)
df_sih['competencia'] = df_sih['competencia'].astype(str).str.strip()

df_cnes['codigo_cnes']= df_cnes['codigo_cnes'].astype(str).str.strip().str.zfill(7)
df_cnes['competencia'] = df_cnes['competencia'].astype(str).str.strip()


# Left Join no nível Hospital-Mês
df_base_modelagem = pd.merge(
    df_sih,
    df_cnes,
    on=['codigo_cnes', 'competencia'],
    how='left',
    suffixes=('', '_cnes')
)
```


Algoritmo 1. Script para o criação de competência temporal e junção de bases. Fonte: Dados originais da pesquisa.

A base de dados integrada final apresentou taxa de correspondência superior a 98% entre os registros do SIH e do CNES. Identificou-se assimetria na distribuição da variável-alvo, com 376.410 registros de alta (90,62%) e 38.957 óbitos (9,38%), configurando um desbalanceamento de classes de aproximadamente 9:1 que exigiu tratamento específico nas etapas subsequentes de modelagem.

Construção do indicador de estrutura hospitalar

Para investigar a hipótese central deste trabalho, de que o desfecho clínico depende não apenas do risco individual do paciente, mas também da capacidade estrutural do hospital que o atendeu, foi construído um escore de estrutura hospitalar (0 a 3) a partir de três critérios do CNES: (i) habilitação em cardiologia intervencionista (cateterismo/cirurgia cardiovascular, exceto transplante); (ii) disponibilidade de leito complementar (Unidade de Terapia Intensiva); e (iii) habilitação para transplante cardíaco. A soma dos três critérios originou quatro categorias: Baixa (escore 0), Média (escore 1), Alta (escore 2) e Muito Alta (escore 3). [adicionar aqui alguns resultados que mostram o quanto tivemos de cada hospital]





[FIGURA: um gráfico mostrando quantos hospitais/internações caem em cada categoria de estrutura]

Engenharia de Features

Além das variáveis originais das bases SIH e CNES, foram construídas features derivadas com vistas a incorporar conhecimento clínico ao processo de modelagem, aumentando a capacidade do modelo de capturar dimensões de risco não diretamente observáveis nos registros administrativos brutos.

O `escore_fragilidade` foi calculado como função linear ponderada da idade e do número de comorbidades secundárias registradas na internação, operacionalizado por meio da expressão: $\text{escore} = 0,4 \times \text{idade_normalizada} + 0,6 \times \text{n_comorbidades_normalizado}$. Esse índice sintetiza em um único atributo a vulnerabilidade clínica preexistente do paciente, inspirando-se nos critérios de fragilidade amplamente referenciados na literatura geriátrica e cardiológica (Précoma et al., 2019), e figurou como o preditor de maior importância global no gráfico SHAP do modelo campeão.

O `volume_hospitalar_anual` foi estimado como o número total de internações por IAM registradas em cada estabelecimento no ano da admissão do paciente, funcionando como proxy de experiência institucional e volume-resultado no manejo da síndrome coronariana aguda, relação amplamente documentada na literatura de qualidade assistencial em cardiologia.

A `razao_leitos_uti` foi calculada como a proporção de leitos de Unidade de Terapia Intensiva em relação ao total de leitos hospitalares registrados no CNES no mês da internação, capturando a capacidade relativa de suporte intensivo de cada estabelecimento.

As três features foram derivadas exclusivamente a partir de variáveis disponíveis no momento da admissão, sem acesso a informações de evolução intra-hospitalar, preservando a integridade preditiva do modelo e a inexistência de vazamento de dados.

Seleção de variáveis e pré-processamento

O conjunto de dados inicial, resultante da integração entre as bases SIH e CNES e enriquecido com as features derivadas descritas na subseção anterior, foi submetido a um processo de redução de dimensionalidade estruturado em etapas sequenciais. Removeram-se, em primeiro lugar, as variáveis caracterizadas como vazamento de dados (data leakage): campos relacionados ao desfecho ou conhecidos apenas ao final da internação, como o motivo de saída, a data de saída e o tempo total de permanência e suas variáveis derivadas (dias de permanência, diárias faturadas e indicadores de uso acumulado de Unidade de Terapia Intensiva). A exclusão dessas variáveis foi motivada pelo fato de que seu uso comprometeria a validade preditiva do modelo ao antecipar, no momento da admissão, informações que só se tornam disponíveis ao longo ou ao final da internação. Eliminaram-se, em seguida, as colunas constantes e quase-constantes, definidas por concentrarem mais de 98% dos registros em uma única categoria. Descartaram-se ainda variáveis textuais de alta cardinalidade não computáveis.

Diferentemente de abordagens convencionais que empregam filtros de correlação linear prévia (Pearson), optou-se por não aplicar corte de correlação como etapa de seleção de variáveis para os modelos baseados em árvore. Essa decisão fundamenta-se no fato de que algoritmos como XGBoost e LightGBM capturam relações não-lineares e interações multidimensionais por meio do Information Gain (critérios de Gini e Entropia), sendo capazes de operar sobre espaços de alta dimensionalidade e descartar, via ganho de informação nulo, as variáveis que não contribuem para a predição (Chen e Guestrin, 2016; Ke et al., 2017). Adicionalmente, ambos os modelos contam com regularização nativa nos parâmetros reg_alpha (L_1) e reg_lambda (L_2), tornando-os intrinsecamente robustos ao ruído dimensional. Um pré-corte linear poderia eliminar variáveis cujo efeito preditivo é exclusivamente não-linear ou condicional à interação com outros atributos. Para a Regressão Logística, a regularização foi incorporada internamente ao pipeline via penalização L_2 , dispensando igualmente o filtro externo de correlação. Como limitação, reconhece-se que a adoção de métricas de associação mais robustas para variáveis categóricas, como o V de Cramér ou a Informação Mútua, representa um refinamento pertinente para trabalhos futuros.

Os atributos remanescentes passaram por adequações de formatação para inserção nos algoritmos de aprendizado de máquina: variáveis categóricas foram transformadas em formato binário por meio de One-Hot Encoding, expandindo o espaço de características. Valores nulos residuais foram tratados via imputação estatística, mediana para atributos numéricos e moda para atributos categóricos, e a padronização de escala das grandezas contínuas foi realizada por meio do estimador StandardScaler. Todas essas transformações foram ajustadas exclusivamente com o conjunto de treinamento e apenas aplicadas (transform) ao conjunto de teste, de modo a preservar a integridade da avaliação out-of-time.

O conjunto de dados inicial, resultante da integração entre as bases SIH e CNES, foi submetido a um processo de redução de dimensionalidade estruturado em etapas sequenciais. Removeram-se, em primeiro lugar, as variáveis caracterizadas como vazamento de dados (*data leakage*), campos relacionados ao desfecho ou conhecidos apenas ao final da internação, como o motivo de saída, a data de saída e o tempo total de permanência e suas variáveis derivadas (dias de permanência, diárias faturadas e indicadores de uso acumulado de Unidade de Terapia Intensiva). A exclusão dessas variáveis foi motivada pelo fato de que seu uso comprometeria a validade preditiva do modelo ao antecipar, no momento da admissão, informações que só se tornam disponíveis ao longo ou ao final da internação, o que inflaria artificialmente o desempenho do modelo sem correspondência com sua real capacidade preditiva em um cenário de uso clínico efetivo. Eliminaram-se, em seguida, as colunas constantes e quase-constantes, definidas por concentrarem mais de 98% dos registros em uma única categoria. Descartaram-se ainda variáveis textuais de alta cardinalidade não computáveis.

Além das variáveis originais das bases SIH e CNES, foram construídas features derivadas com vistas a incorporar conhecimento clínico ao processo de modelagem. O *escore_fragilidade* foi calculado como função linear ponderada da idade e do número de comorbidades secundárias registradas, com base nos critérios de fragilidade clínica amplamente referenciados na literatura geriátrica e cardiológica (Précoma et al., 2019). O *volume_hospitalar_anual* foi estimado como o número total de internações por IAM registradas em cada estabelecimento no ano da admissão, funcionando como proxy de experiência institucional no manejo da síndrome coronariana aguda. A *razao_leitos_uti* foi calculada como a proporção de leitos de Unidade de Terapia Intensiva em relação ao total de leitos hospitalares, capturando a capacidade de suporte intensivo relativa de cada estabelecimento. Essas features foram derivadas exclusivamente a partir de variáveis disponíveis no momento da admissão, sem acesso a informações de evolução intra-hospitalar, preservando a integridade preditiva do modelo.

Diferentemente de abordagens convencionais que empregam filtros de correlação linear prévia (Pearson), optou-se por não aplicar corte de correlação como etapa de seleção

de variáveis para os modelos baseados em árvore. Essa decisão fundamenta-se no fato de que algoritmos como XGBoost e LightGBM capturam relações não-lineares e interações multidimensionais por meio do Information Gain (critérios de Gini e Entropia), sendo capazes de operar sobre espaços de alta dimensionalidade e descartar, via ganho de informação nulo, as variáveis que não contribuem para a predição (Chen e Guestrin, 2016; Ke et al., 2017). Adicionalmente, ambos os modelos contam com regularização nativa nos parâmetros reg_alpha (L_1) e reg_lambda (L_2), o que os torna intrinsecamente robustos ao ruído dimensional. Um pré-corte linear poderia, nesse contexto, eliminar variáveis cujo efeito preditivo é exclusivamente não-linear ou condicional à interação com outros atributos como, por exemplo, a combinação entre gravidade clínica e tipo de estrutura hospitalar. Para a Regressão Logística, modelo de caráter linear, a regularização foi incorporada internamente ao pipeline via penalização L_2 , dispensando igualmente o filtro externo de correlação.

Como limitação, reconhece-se que a adoção de métricas de associação mais robustas para variáveis categóricas, como o V de Cramér ou a Informação Mútua (mutual information), representa um refinamento metodológico pertinente para trabalhos futuros, especialmente para a etapa de pré-seleção em bases de muito alta dimensionalidade.

Os atributos remanescentes passaram por adequações de formatação para inserção nos algoritmos de aprendizado de máquina: variáveis categóricas foram transformadas em formato binário por meio de One-Hot Encoding, expandindo o espaço de características. Valores nulos residuais foram tratados via imputação estatística, mediana para atributos numéricos e moda para atributos categóricos, e a padronização de escala das grandezas contínuas foi realizada por meio do estimador StandardScaler. Todas essas transformações, por envolverem o aprendizado de estatísticas a partir dos dados (medianas, modas, médias e desvios-padrão), foram ajustadas exclusivamente com o conjunto de treinamento e apenas aplicadas (transform) ao conjunto de teste, de modo a preservar a integridade da avaliação out-of-time.

Modelagem preditiva, desbalanceamento e validação

A divisão dos dados em conjuntos de treinamento e teste seguiu uma estratégia temporal, e não aleatória: os registros correspondentes ao período de 2015 a 2022 constituíram o conjunto de treinamento, enquanto os dados referentes a 2023 a 2025 foram reservados como conjunto de teste out-of-time. Essa escolha se justifica pela natureza longitudinal dos dados administrativos, que abrangem mais de uma década de mudanças em protocolos hospitalares, infraestrutura e perfil epidemiológico da população. Um particionamento aleatório permitiria que o modelo fosse treinado com registros futuros e testado em registros passados, configurando viés de antecipação (look-ahead bias) e inflando artificialmente as métricas de desempenho.

A modelagem preditiva baseou-se na comparação de quatro algoritmos: Regressão Logística Múltipla, Random Forest, Extreme Gradient Boosting [XGBoost] e Light Gradient Boosting Machine [LightGBM]. Para tratar o desbalanceamento intrínseco da variável-alvo (proporção de aproximadamente 9,66:1 entre altas hospitalares e óbitos no conjunto de treinamento, totalizando 376.410 e 38.957 registros, respectivamente), optou-se pela parametrização nativa das funções de custo de cada algoritmo, evitando técnicas de reamostragem sintética como o SMOTE, que pode introduzir viés por interpolação em espaços de alta dimensionalidade. Para o XGBoost, adotou-se o parâmetro $\text{scale_pos_weight} = \sqrt{(n_{\text{negativos}} / n_{\text{positivos}})} = \sqrt{(376.410 / 38.957)} \approx 3,106$, equivalente à raiz quadrada da razão de desbalanceamento. A escolha da raiz quadrada, em vez da proporção bruta (9,66), é deliberada: o peso direto tornaria o modelo excessivamente sensível à classe minoritária, elevando o Recall à custa de uma precisão proibitivamente baixa para uso clínico. A raiz quadrada constitui um compromisso calibrado entre recuperação de casos positivos e controle de falsos alarmes (He e Garcia, 2009). Para os demais modelos, utilizou-se o parâmetro `class_weight='balanced'`, que pondera os exemplos inversamente à frequência de suas classes.

Para o modelo de melhor desempenho, o limiar de decisão padrão de 0,5 foi substituído por um threshold ótimo, determinado pela maximização do F1-Score na curva Precision-Recall calculada sobre o conjunto de treinamento. Esse procedimento é especialmente relevante em contextos clínicos: o threshold padrão pressupõe custos simétricos entre falsos positivos e falsos negativos, premissa inadequada para triagem de risco hospitalar, em que a omissão de um caso grave (falso negativo) tem consequências clínicas muito mais severas do que um alarme excessivo (falso positivo). O threshold ótimo identificado sobre o conjunto de treino foi então aplicado diretamente ao conjunto de teste out-of-time, sem qualquer reajuste, preservando o protocolo de avaliação cega.

A validação interna do conjunto de treinamento ocorreu mediante validação cruzada estratificada em cinco vias (*Stratified 5-Fold Cross-Validation*), restrita ao período de treinamento, sem qualquer contato com o conjunto de teste. Os hiperparâmetros dos modelos baseados em árvore não foram otimizados por meio de busca exaustiva, tendo sido fixados empiricamente com base na literatura técnica e validados quanto à estabilidade nas métricas da validação cruzada, a exemplo do XGBoost, modelo de melhor desempenho final, foi configurado com `n_estimators=1000`, `max_depth=7`, `learning_rate=0,02`, `min_child_weight=12`, `colsample_bytree=0,5`, `subsample=0,8`, `reg_alpha=1,0` e `reg_lambda=15,0`. A combinação de regularização L_1 e L_2 forte visa mitigar o sobreajuste potencializado pelo severo desbalanceamento das classes, enquanto o `min_child_weight` elevado impõe restrição mínima de exemplos por folha, estabilizando o aprendizado em

regiões de baixa densidade como as observações de óbito. O LightGBM foi configurado com `n_estimators=1000`, `max_depth=10`, `learning_rate=0,02` e `num_leaves=63`

```
# Split Temporal: treino 2015-2022 · teste 2023-2025
ANO_CORTE = 2023

df['ano_competencia'] = df['ano_competencia'].astype(str).str[:4]

df_treino = df[df['ano_competencia'] < str(ANO_CORTE)].copy()
df_teste = df[df['ano_competencia'] >= str(ANO_CORTE)].copy()
col_ano = 'ano_competencia'

X_treino_raw = df_treino.drop(columns=['indicador_obito', col_ano, 'mes_competencia', 'competencia',
'data_internacao', 'codigo_cnes', 'uti_mes_total_cod', 'diarias_acompanhante', 'quantidade_diarias',
'valor_servicos_hospitalares', 'valor_servicos_profissionais', 'valor_total', 'valor_uti',
'valor_total_dolar', 'dias_permanencia_cod', 'tipo_uti', 'diarias', 'custo'], errors='ignore')
y_train = df_treino['indicador_obito']

X_teste_raw = df_teste.drop(columns=['indicador_obito', col_ano, 'mes_competencia', 'competencia',
'data_internacao', 'codigo_cnes', 'uti_mes_total_cod', 'diarias_acompanhante', 'quantidade_diarias',
'valor_servicos_hospitalares', 'valor_servicos_profissionais', 'valor_total', 'valor_uti',
'valor_total_dolar', 'dias_permanencia_cod', 'tipo_uti', 'diarias', 'custo'], errors='ignore')
y_test = df_teste['indicador_obito']

cat_cols = X_treino_raw.select_dtypes(include=['object', 'category']).columns.tolist()

X_train = pd.get_dummies(X_treino_raw, columns=cat_cols, drop_first=True)
X_test = pd.get_dummies(X_teste_raw, columns=cat_cols, drop_first=True)

X_train, X_test = X_train.align(X_test, join='left', axis=1, fill_value=0)

clean = lambda cols: [re.sub(r'[\[\]<>\s]', '_', c) for c in cols]
X_train.columns = clean(X_train.columns)
X_test.columns = clean(X_test.columns)

# --- XGBoost ---
xgb_model = XGBClassifier(
    device='cuda', tree_method='hist',
    n_estimators=1000, max_depth=7,
    learning_rate=0.02, min_child_weight=12,
    colsample_bytree=0.5, subsample=0.8,
    scale_pos_weight=scale_weight,
    reg_alpha=1.0, reg_lambda=15.0,
    random_state=42
)
xgb_model.fit(X_train, y_train)
y_prob_xgb = xgb_model.predict_proba(X_test)[: , 1]
# Threshold ótimo via curva Precision-Recall (treino)
precisions, recalls, thresholds = precision_recall_curve(y_train,
                                                         xgb_model.predict_proba(X_train)[: , 1])
```

```
f1_scores = 2 * (precisions[:-1] * recalls[:-1]) / (precisions[:-1] + recalls[:-1] + 1e-9)
optimal_threshold = thresholds[np.argmax(f1_scores)]
y_pred_xgb = (y_prob_xgb >= optimal_threshold).astype(int)
```

[CÓDIGO: split temporal e treinamento de um dos modelos]

A comparação de desempenho entre os modelos baseou-se na Área Sob a Curva Característica de Operação do Receptor (AUC-ROC)[Dado o desbalanceamento de 9:1, recomendo reportar também a PR-AUC (Precision-Recall) e a calibração (Brier Score).], calculada tanto na validação cruzada do treino quanto no conjunto de teste out-of-time, submetida ao teste de DeLong para aferir a significância estatística das diferenças entre os algoritmos.

O Notebook 06 busca o threshold ótimo pelo F1-Score máximo na curva Precision-Recall do treino, aplicado ao teste. Isso permite equilibrar Recall e Precision para o contexto clínico (não usar threshold fixo de 0,5).

[FIGURA: curvas ROC dos quatro modelos]

Análise da interação entre risco clínico e estrutura hospitalar

Para testar diretamente a hipótese de que o desfecho depende da combinação entre risco individual e capacidade estrutural do hospital, foi conduzida uma análise de estratificação cruzada. As probabilidades de óbito preditas pelo modelo de melhor desempenho, calculadas exclusivamente a partir de variáveis do paciente e do curso clínico da internação, foram segmentadas em tercís de risco (baixo, médio, alto). Esses tercís foram então cruzados com as quatro categorias do escore de estrutura hospitalar descrito anteriormente, resultando em doze grupos, para os quais se calculou a taxa de mortalidade observada e o respectivo intervalo de confiança de 95%. A significância da diferença de mortalidade entre os doze grupos foi avaliada por meio do teste qui-quadrado de Pearson. Como esse teste captura conjuntamente o efeito principal do risco clínico, o efeito principal da estrutura hospitalar e a eventual interação entre ambos, a significância da interação propriamente dita, isto é, se o efeito da estrutura hospitalar sobre a mortalidade varia conforme o nível de risco clínico do paciente, foi avaliada de forma isolada por meio de um teste de razão de verossimilhança (Likelihood Ratio Test), comparando um modelo de regressão logística com e sem o termo de interação tercil de risco × estrutura hospitalar.

```
# Cria dataframe com as predições de teste
df_interacao = pd.DataFrame({
    "obito_observado": y_test,
    "prob_predita": y_prob
})
```

```
# Cria os tercís de risco (Baixo, Médio, Alto Risco Clínico Previsto pelo ML)
df_interacao["tercil_risco"] = pd.qcut(df_interacao["prob_predita"], q=3, labels=["Baixo Risco",
"Médio Risco", "Alto Risco"])


# Carrega a base enriquecida para recuperar o indicador de estrutura e risco
df_enriched = pd.read_csv("../data/processed/base_modelagem_enriched.csv", low_memory=False)

# Garantir que o index bate
if df_enriched.index.name != 'codigo_internacao':
    if 'codigo_internacao' in df_enriched.columns:
        df_enriched.set_index('codigo_internacao', inplace=True)
    else:
        df_enriched.index = df.index

# Associa a categoria de estrutura à nossa base de teste (mesmos índices)
idx_test = df_interacao.index
df_interacao["categoria_estrutura"] = df_enriched.loc[idx_test, "categoria_estrutura"].values

# Como definimos uma ordem lá no 03b, vamos reforçá-la aqui no Pandas
from pandas.api.types import CategoricalDtype
cat_type = CategoricalDtype(categories=["baixa", "média", "alta", "muito alta"], ordered=True)
df_interacao["categoria_estrutura"] = df_interacao["categoria_estrutura"].astype(cat_type)

tabela_interacao = df_interacao.groupby(["tercil_risco",
"categoria_estrutura"])["obito_observado"].mean().reset_index()
tabela_interacao["obito_observado"] = tabela_interacao["obito_observado"] * 100
[CÓDIGO: construção dos tercís de risco e da tabela cruzada]
```



[FIGURA Gráfico de barras da mortalidade observada por tercil de risco e nível de estrutura]

Interpretabilidade e justiça algorítmica

A avaliação da importância dos preditores foi conduzida pela técnica de SHAP, selecionada em detrimento de métricas nativas de importância de atributos por considerar interações complexas entre variáveis correlacionadas e assegurar a aditividade das contribuições marginais. A aplicação dos valores SHAP permitiu a interpretabilidade global e local do modelo de melhor desempenho, o mesmo modelo cujas probabilidades preditas fundamentaram os tercis de risco clínico da análise de interação, subsidiando a análise de justiça algorítmica ao possibilitar a comparação da distribuição de importância dos preditores entre subgrupos sociodemográficos (sexo, raça/cor).



```
# Amostra de 20000 registros para performance
X_shap = X_test.sample(20000, random_state=42)
shap_values = explainer.shap_values(X_shap)
```

[CÓDIGO: cálculo dos valores SHAP para o modelo campeão XG]

[FIGURA: SHAP summary plot com os principais preditores]

Análise de sobrevivência

A investigação do tempo de sobrevida intra-hospitalar estabeleceu os dias de permanência como variável temporal e o óbito como evento de interesse, com censura à direita para os casos evoluídos para alta hospitalar. Aplicou-se o estimador não paramétrico de Kaplan-Meier para a construção da curva global de sobrevivência e para análises estratificadas por sexo, faixa etária, raça/cor e categoria de estrutura hospitalar, avaliando-se a significância das diferenças por meio do teste de Log-Rank. Para a avaliação multivariável, ajustou-se um modelo semiparamétrico de Riscos Proporcionais de Cox, incorporando as covariáveis idade, sexo, caráter de internação e escore de estrutura hospitalar; a variável de uso de Unidade de Terapia Intensiva foi excluída do modelo por representar informação disponível apenas após a admissão, potencialmente configurando vazamento de dados. A validade do modelo foi verificada pela análise dos resíduos de Schoenfeld quanto à premissa de riscos proporcionais.



[FIGURA: curvas de Kaplan-Meier estratificadas por estrutura hospitalar]

[Inserir o gráfico das curvas de Kaplan-Meier com o número sob risco e p do Log-Rank.]


Vale mencionar, junto do repositório no GitHub ([<https://github.com/Carolina-Silva/TCC>]), que os notebooks completos com a implementação integral encontram-se disponíveis para consulta, servindo este texto como descrição da lógica e das decisões metodológicas centrais.

Resultados e Discussão

Análise exploratória e perfil da amostra

A amostra final compreendeu 415.367 internações por Infarto Agudo do Miocárdio no período de 2015 a 2025. A taxa de letalidade hospitalar geral estabeleceu-se em 9,38%, correspondendo a 38.957 óbitos. O tempo mediano de permanência hospitalar global limitou-se a 3 dias, enquanto a mediana de permanência entre os casos de óbito totalizou 2 dias, evidenciando a concentração do risco nas primeiras horas de internação. A idade média dos pacientes que evoluíram para óbito atingiu 69,4 anos, contrastando com 62,1 anos entre os pacientes que receberam alta. Em relação ao perfil demográfico, a coorte apresentou predominância masculina (63,7%), embora a letalidade feminina tenha superado a masculina (11,2% contra 8,3%).

[TABELA: estatísticas descritivas da amostra idade, tempo de permanência, sexo, desfecho separadas por óbito vs. alta]



[FIGURA: distribuição de idade por desfecho (óbito vs. alta) histograma]

Desempenho dos modelos preditivos

Na etapa de classificação binária supervisionada, o XGBoost destacou-se com o melhor desempenho no conjunto de teste out-of-time, obtendo uma Área Sob a Curva Característica de Operação do Receptor (AUC-ROC) de 0,7826. O LightGBM alcançou AUC-ROC de 0,7794, seguido pelo Random Forest com 0,7649, enquanto a Regressão Logística (modelo base) obteve 0,7227. Observou-se uma diferença relevante entre o desempenho na validação cruzada do treinamento e no teste out-of-time: a Regressão Logística apresentou a maior queda relativa (de 0,7534 para 0,7227), ao passo que os

modelos baseados em árvore mantiveram-se mais próximos de seus valores de validação cruzada (XGBoost: de 0,7940 para 0,7826; LightGBM: de 0,7930 para 0,7794). Esse padrão sugere maior capacidade dos modelos baseados em árvore de capturar relações não lineares e interações entre variáveis que se mantiveram mais estáveis diante da mudança de distribuição ao longo dos anos, enquanto o modelo linear mostrou-se mais sensível ao deslocamento temporal dos dados (data drift).

A aplicação do teste de DeLong confirmou que a diferença entre XGBoost e LightGBM foi estatisticamente significativa ($z = 5,25$; $p = 1,51 \times 10^{-7}$), assim como a superioridade de ambos os modelos de gradient boosting e do Random Forest em relação à Regressão Logística ($p < 0,001$ em todas as comparações).

Modelo	AUC-ROC (Teste)	PR-AUC	Brier Score	Recall	Precision	F1
Regressão Logística	0,7293	0,1727	0,2139	66,86%	15,49%	0,252
Random Forest	0,7758	0,2762	0,1833	66,67%	18,11%	0,285
LightGBM	0,7961	0,3275	0,1560	66,36%	19,92%	0,306
XGBoost	0,8007	0,3282	0,0854	34,04%	35,36%	0,347


[TABELA: AUC-ROC CV (treino) vs. teste out-of-time para os quatro modelos]

O XGBoost obteve AUC-ROC de 0,8007 no conjunto de teste out-of-time, superando o LightGBM (0,7961), o Random Forest (0,7758) e a Regressão Logística (0,7293). O desempenho superior do XGBoost é confirmado pelo teste de DeLong: a superioridade sobre o LightGBM é estatisticamente significativa ($z = 7,60$; $p = 2,84 \times 10^{-14}$), assim como sobre o Random Forest ($z = 23,70$; $p < 10^{-100}$) e sobre a Regressão Logística ($z = 40,45$; $p < 10^{-100}$).

Em termos de calibração probabilística, o XGBoost apresentou o menor Brier Score (0,0854), indicando que as probabilidades preditas se aproximam com maior fidedignidade das frequências observadas de óbito. Esse resultado é relevante do ponto de vista clínico, pois sistemas de estratificação de risco que operam sobre probabilidades descalibradas podem levar a alocações de recursos sistematicamente equivocadas. A PR-AUC do XGBoost (0,3282) foi também superior à dos demais modelos, evidência especialmente importante dado o severo desbalanceamento das classes: em cenários de

desbalanceamento, a curva Precision-Recall é mais informativa do que a curva ROC, por não incorporar os verdadeiros negativos, classe largamente dominante, no cálculo da métrica (Saito e Rehmsmeier, 2015).

Observou-se que os modelos da Regressão Logística, Random Forest e LightGBM, ao operarem com o limiar padrão de 0,5, apresentaram Recall elevado (acima de 66%) porém Precision baixa (inferior a 20%), refletindo uma tendência a classificar como positivos um número excessivo de pacientes. O XGBoost, com threshold ajustado via maximização do F1-Score, atingiu um equilíbrio entre Recall (34,04%) e Precision (35,36%), o que representa uma triagem clinicamente mais controlada, com menor taxa de alarmes falsos. Essa diferença é coerente com o papel distinto do threshold de decisão na configuração operacional do modelo.



[FIGURA: curvas ROC dos quatro modelos]


Interação entre risco clínico e estrutura hospitalar

Esta seção reporta o achado central deste trabalho. A segmentação das probabilidades preditas pelo modelo XGBoost em tercis de risco clínico, cruzada com as quatro categorias do escore de estrutura hospitalar, revelou um padrão mais complexo do

que uma simples atenuação do efeito estrutural entre os pacientes mais graves. No tercil de alto risco, a mortalidade observada cresceu de forma consistente com o nível de estrutura hospitalar, de 13,49% em hospitais de estrutura baixa para 19,99% em hospitais de estrutura muito alta, uma diferença de 6,5 pontos percentuais, a maior entre os três tercis. No tercil de baixo risco, o padrão não foi monotônico: hospitais de estrutura muito alta (2,32%) apresentaram mortalidade superior à de hospitais de estrutura alta (1,46%) e média (0,81%), embora inferior à de hospitais de baixa estrutura (3,26%).

O teste qui-quadrado de Pearson confirmou diferença altamente significativa na distribuição de óbitos entre os doze grupos ($\chi^2(11) = 8.371,27$; $p < 0,001$). De forma mais específica, o teste de razão de verossimilhança sobre o termo de interação tercil de risco $\times$ estrutura hospitalar indicou que o efeito da estrutura hospitalar sobre a mortalidade não é uniforme entre os níveis de risco clínico (LR $\chi^2(6) = 50,99$; $p < 0,001$), confirmando estatisticamente a existência de modificação de efeito, e não apenas um efeito aditivo e independente dos dois fatores.

Diferentemente da hipótese inicial, de que a estrutura hospitalar teria maior peso protetor entre pacientes clinicamente saudáveis, os resultados indicam que hospitais de maior estrutura estiveram associados a maior, e não menor, mortalidade condicional ao risco, sobretudo entre os pacientes mais graves. Esse padrão é mais consistente com um efeito de concentração de gravidade por referenciamento do que com um efeito protetor direto da estrutura: hospitais de maior complexidade tendem a concentrar, por regionalização da rede assistencial, os casos clinicamente mais graves, inclusive dentro de um mesmo tercil de risco estimado pelo modelo, que pode não capturar integralmente a gravidade real do paciente no momento da admissão.



[FIGURA barras agrupadas com a mortalidade observada nas 12 células de tercil de risco × estrutura hospitalar]

Esse resultado tem uma implicação direta para a discussão que se segue: um modelo de estratificação de risco baseado apenas em variáveis do paciente, por mais discriminativo que seja isoladamente (seção anterior), é insuficiente para explicar o desfecho hospitalar a mesma probabilidade de risco estimada pode se traduzir em taxas de mortalidade muito diferentes a depender do hospital de destino, e essa diferença parece refletir, ao menos em parte, para quais hospitais os casos mais graves são direcionados, e não necessariamente a qualidade assistencial de cada nível de estrutura.

Interpretabilidade e Justiça Algorítmica

Importância Global das Features (SHAP Summary)


Para além das métricas preditivas, a interpretabilidade do modelo XGBoost foi investigada por meio dos valores SHAP (*SHapley Additive exPlanations*), que decompõem a contribuição de cada variável para a predição individual de risco de óbito. A [Figura N] apresenta o *summary plot* de beeswarm para uma amostra de 2.000 registros do conjunto de teste, evidenciando tanto a magnitude quanto a direção do efeito de cada preditor.

A variável `idade` destacou-se como o fator de maior importância global, com valores SHAP que alcançam amplitude superior a 1,0 na escala de log-odds: pacientes mais idosos (valores da feature em vermelho) apresentam consistentemente SHAP positivos, indicando elevação do risco de óbito, enquanto pacientes mais jovens concentram SHAP negativos, exercendo efeito protetor. Esse padrão é coerente com a fisiopatologia do IAM e com a literatura epidemiológica que aponta a idade como principal fator de risco para mortalidade intra-hospitalar por síndrome coronariana aguda.

O `procedimento\_realizado\_cod` posicionou-se como segundo preditor em importância, com SHAP predominantemente negativos associados a valores altos da feature, sugerindo que determinados procedimentos de maior complexidade/intervenção (como cateterismo e angioplastia, códigos de maior valor numérico) estão associados à redução do risco de óbito, possivelmente por representarem acesso efetivo a tratamento intervencionista. O `tipo\_gestor`, em terceiro lugar, apresentou SHAP fortemente negativos para valores altos: estabelecimentos de gestão privada/federal (códigos mais elevados) associam-se a menor risco de óbito, refletindo diferenças estruturais e de capacidade instalada entre os tipos de gestão do SUS. O `tipo\_diag\_sec\_2\_cod`, relativo ao diagnóstico secundário codificado, apresentou SHAP positivos para valores elevados, indicando que comorbidades específicas elevam o risco de desfecho fatal.

Entre as variáveis de infraestrutura hospitalar, `qtd\_leitos\_cirurgicos` apareceu na 11ª posição do ranking de importância global, com SHAP predominantemente negativos para valores altos, ou seja, hospitais com maior número de leitos cirúrgicos associam-se a menor probabilidade de óbito, confirmando a hipótese central deste estudo de que a estrutura do estabelecimento exerce influência independente sobre o desfecho, além das características clínicas do paciente.


[FIGURA: SHAP summary plot]



Ranking de Importância Absoluta (SHAP Bar Plot)

A [Figura1] confirma a hierarquia de importância por meio da importância SHAP média absoluta, métrica que captura a magnitude do efeito independentemente de sua direção. `Idade` (média |SHAP| $\approx 0,43$) e `procedimento\_realizado\_cod` ($\approx 0,35$) concentram, de forma conjunta, a maior parcela da capacidade preditiva do modelo. As variáveis

`tipo\_gestor` ($\approx 0,24$) e `tipo\_diag\_sec\_2\_cod` ($\approx 0,18$) completam o quarteto dominante. A partir da quinta posição, as contribuições individuais decrescem de forma acentuada, com `tipo\_diag\_sec\_1\_Preexistente`, `carater\_internacao\_Urgência` e os demais preditores apresentando importância média inferior a 0,10, indicando que o poder preditivo do modelo está relativamente concentrado em um subconjunto de quatro variáveis principais.



[Figura N+1. Importância SHAP média absoluta das 15 principais variáveis do modelo XGBoost. Fonte: Resultados originais da pesquisa.]


Análise de Equidade por Sexo

A análise de equidade (*fairness*) por sexo examinou se o modelo atribui importâncias e efeitos distintos a pacientes masculinos e femininos, o que poderia indicar viés sistemático.


As [Figuras N+2 e N+3] apresentam os *summary plots* SHAP para cada subgrupo (n=1.000 por amostragem).

Em ambos os grupos, as mesmas variáveis dominam o ranking: `idade`, `procedimento\_realizado\_cod` e `tipo\_gestor` ocupam as três primeiras posições, com padrões de direção de efeito consistentes, idade avançada eleva o risco, procedimentos intervencionistas e gestão privada/federal reduzem o risco de óbito. Essa estabilidade na hierarquia de preditores sugere que o modelo não discrimina de forma estrutural entre os sexos na atribuição de risco.

Uma diferença sutil foi observada no comportamento de `carater\_internacao\_Urgência`: no subgrupo masculino, a feature apresenta dispersão de SHAP ligeiramente maior à esquerda (efeito protetor em internações programadas mais frequentes), enquanto no subgrupo feminino a variável `sexo\_Masculino` aparece com SHAP próximos de zero, o que é esperado, dado que essas pacientes são codificadas como 0 nessa feature binária. Não foram identificados padrões que indiquem viés sistemático do modelo na atribuição de risco entre os dois grupos sexuais.



[Figura N+2. Valores SHAP para pacientes masculinos (n=1.000). Fonte: Resultados originais da pesquisa.]`




[Figura N+3. Valores SHAP para pacientes femininos (n=1.000). Fonte: Resultados originais da pesquisa.]`

estudo por raça não será utilizado por tem alto índice de não informado

Análise de sobrevivência

Na modelagem temporal, a curva de Kaplan-Meier revelou uma mediana de sobrevivência hospitalar de [falta] dias. O teste de Log-Rank indicou diferença estatisticamente significativa nas curvas de sobrevida entre sexos ($p < 0,005$), faixas etárias ($p < 0,005$ em todas as comparações par a par) e raça/cor (significativo em nove das dez comparações par a par, com exceção de Branca versus Amarela, $p = 0,232$). Entre as

categorias de estrutura hospitalar, o teste par a par indicou diferenças significativas na maioria das comparações, exceto entre estrutura Baixa e Muito Alta ($p = 0,495$), resultado consistente com o padrão não monotônico já observado na análise de interação, sugerindo que hospitais de baixa e de muito alta estrutura atendem, cada um a seu modo, subpopulações de gravidade elevada.



[FIGURA: curvas de Kaplan-Meier estratificadas por estrutura hospitalar]

O modelo de Riscos Proporcionais de Cox, incorporando as covariáveis idade, sexo, caráter de internação e escore de estrutura hospitalar, apresentou um Índice de Concordância (C-statistic) de 0,65. As variáveis sexo (Schoenfeld, $p = 0,36$) e caráter de internação ($p = 0,38$) atenderam à premissa de riscos proporcionais, permitindo interpretação direta de seus Hazard Ratios: internações de urgência apresentaram risco 72% maior em comparação aos atendimentos eletivos ($HR = 1,72$), e o sexo associou-se a um risco 12% maior ($HR = 1,12$). Já as variáveis idade ($p = 1,18 \times 10^{-74}$) e escore de estrutura hospitalar ($p = 3,74 \times 10^{-97}$) violaram essa premissa, indicando que seus efeitos sobre o risco de óbito não são constantes ao longo da internação, mas se modificam conforme o tempo decorrido, achado consistente com o observado na análise de interação, e que reforça a ideia de que tanto o risco clínico do paciente quanto o peso da estrutura hospitalar sobre esse risco são dinâmicos, não uma fotografia única tirada no momento da admissão. Esse comportamento não constante é esperado na fisiopatologia do IAM: o risco de óbito concentra-se de forma hiperaguda nas primeiras 48 horas de internação, período da fase

isquêmica ativa, reduzindo-se progressivamente nos dias seguintes, de modo que um *hazard ratio* único seria uma simplificação inadequada para um desfecho com essa dinâmica temporal. Por essa razão, os Hazard Ratios de idade (1,05) e de estrutura hospitalar (1,05) devem ser interpretados como aproximações de um efeito médio ao longo da internação, e não como efeitos pontuais constantes. Notavelmente, o sinal positivo do coeficiente de estrutura hospitalar, indicando maior, não menor, risco instantâneo de óbito associado a hospitais de maior estrutura, corrobora, sob a ótica da sobrevivência, a mesma leitura de concentração de gravidade por referenciamento discutida na seção anterior.

Limitações do estudo

Por tratar-se de um estudo fundamentado em registros administrativos e de faturamento do DATASUS, a modelagem está sujeita a vieses de subnotificação e ruídos de codificação. A base de dados carece de variáveis clínicas e laboratoriais de alta granularidade cruciais para a estratificação do risco miocárdico, tais como marcadores bioquímicos, achados eletrocardiográficos e a latência de atendimento, o que impõe um teto ao potencial preditivo dos algoritmos. O escore de estrutura hospitalar utilizado, embora clinicamente orientado, constitui uma simplificação de uma realidade multidimensional; ademais, a associação identificada entre estrutura hospitalar e mortalidade deve ser interpretada à luz de um provável viés de seleção por referenciamento, pacientes atendidos em hospitais de diferentes níveis de estrutura não constituem amostras aleatórias da população de IAM, o que impede a atribuição de causalidade direta ao efeito da estrutura sobre o desfecho. Por fim, a violação da premissa de riscos proporcionais em parte das covariáveis do modelo de Cox aponta para a necessidade, em desenvolvimentos futuros, de abordagens como modelos de Cox estratificados ou regressões de riscos competitivos.

Conclusão(ões)

A implementação dos algoritmos de aprendizado de máquina evidenciou capacidade discriminativa moderada para a predição do risco de letalidade por infarto agudo do miocárdio a partir de dados administrativos do SUS (AUC-ROC de 0,78 para o modelo de melhor desempenho, XGBoost). Contudo, o achado central deste trabalho ultrapassou a questão do desempenho isolado dos modelos: demonstrou-se que o risco individual do paciente, por si só, não determina o desfecho, a mortalidade observada variou de forma significativa conforme a estrutura do hospital responsável pelo atendimento, e essa variação não foi uniforme entre os níveis de risco clínico (teste de razão de verossimilhança sobre o termo de interação, $p < 0,001$). Contrariamente à hipótese inicial de que a estrutura hospitalar exerceria um efeito predominantemente protetor entre os pacientes clinicamente mais salváveis, a maior diferença de mortalidade entre níveis de estrutura hospitalar ocorreu justamente entre os pacientes classificados no tercil de maior risco clínico (variação de 13,49% para 19,99% entre estrutura baixa e muito alta), enquanto entre os pacientes de menor risco o padrão não foi monotônico. Esse resultado é mais consistente com um efeito de concentração de casos graves em hospitais de maior complexidade, por regionalização da rede assistencial, do que com um efeito causal direto e protetor da estrutura sobre o desfecho.

Esse resultado foi corroborado pela análise de sobrevivência: a violação da premissa de riscos proporcionais nas covariáveis idade e escore de estrutura hospitalar indicou que o risco de óbito não permanece constante ao longo da internação, e que o próprio peso da estrutura hospitalar sobre esse risco também se modifica com o tempo decorrido de internação, reforçando que a estratificação de risco realizada exclusivamente no momento da admissão, prática comum em ferramentas de triagem hospitalar, é insuficiente para capturar a dinâmica real do desfecho clínico.

Conclui-se que a principal contribuição deste estudo para a gestão em saúde pública não é apenas a existência de um modelo preditivo de discriminação moderada, mas a evidência de que risco clínico e capacidade estrutural interagem estatisticamente na determinação do desfecho hospitalar por IAM no SUS, interação essa que parece refletir, sobretudo, padrões de referenciamento de casos graves para centros de maior complexidade, e não um efeito protetor direto da estrutura. Do ponto de vista de política pública, isso sugere que análises de mortalidade hospitalar bruta, comparadas entre hospitais sem ajuste adequado por gravidade e por padrão de referenciamento, podem mascarar o real desempenho assistencial de cada nível da rede, com risco de conclusões equivocadas sobre a efetividade de centros de referência que, na verdade, atendem a população sistematicamente mais grave.

Diante das limitações inerentes aos dados administrativos utilizados, em especial a ausência de variáveis clínicas de alta granularidade, o provável viés de seleção por referenciamento entre níveis de estrutura hospitalar, e a violação parcial da premissa de riscos proporcionais, abrem-se perspectivas claras para trabalhos futuros. Recomenda-se o aprofundamento da análise de interação entre risco clínico e estrutura hospitalar por meio de valores de interação SHAP, permitindo uma quantificação mais granular do efeito identificado neste trabalho, bem como a incorporação de indicadores de gravidade na admissão não capturados pelo escore de risco atual (como tempo de transferência entre unidades), de modo a mitigar o viés de referenciamento discutido. Sugere-se ainda a adoção de modelos de Cox estratificados ou de regressões de riscos competitivos (método de Fine-Gray) para acomodar a heterogeneidade temporal do risco observada, assim como a incorporação de variáveis clínicas laboratoriais em desenvolvimentos futuros, caso venham a se tornar disponíveis em bases de dados administrativas de maior granularidade.

Agradecimento (opcional, 1 parágrafo, bem sucinto)

O título da seção Agradecimentos deve ser alinhado à esquerda e grafado em negrito, com a primeira letra da palavra grafada em letra maiúscula. Trata-se de uma seção opcional, de no máximo três linhas, na qual o autor agradece àqueles que contribuíram de maneira relevante para o desenvolvimento do trabalho e elaboração do TCC, mas que não tiveram o envolvimento intelectual necessário à atribuição de coautoria. O autor deve se abster da menção ou citação dos nomes das empresas, instituições ou pessoas que permitiram ou contribuíram com o desenvolvimento do trabalho, a menos que esteja documentalmente autorizado a fazê-lo.

Atenção: antes de enviar o arquivo para o Sistema de TCCs, remova todas as instruções originais que estão abaixo do conteúdo dos tópicos.

Referências

Chen & Guestrin para o XGBoost, Cox 1972, etc.

Jayaprasad N. Heart Failure in Children. Heart Views. 2016 Jul-Sep;17(3):92-99. doi: 10.4103/1995-705X.192556. PMID: 27867456; PMCID: PMC5105230.

Cavalheiro, W. S. et al. 2024. Epidemiologia do infarto agudo do miocárdio no Brasil: análise das internações e mortalidade (2014-2023). Revista Contribuciones a las Ciencias Sociales 17(12).

Chen, T.; Guestrin, C. 2016. XGBoost: A scalable tree boosting system. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining: 785-794.

Coughlin, S. S.; Young, L. 2020. Social determinants of myocardial infarction risk and survival: a systematic review. European Journal of Cardiovascular Research 1(1).

Cox, D. R. 1972. Regression models and life-tables. Journal of the Royal Statistical Society: Series B (Methodological) 34(2): 187-202.

Escosteguy, C. C. et al. 2002. O sistema de informações hospitalares e a assistência ao infarto agudo do miocárdio. Revista de Saúde Pública.

Fawcett, T. 2006. An introduction to ROC analysis. Pattern Recognition Letters 27(8): 861-874.

Gamarski, R. et al. 2024. A frequência de doenças cardiovasculares na artrite reumatoide no Brasil: estudo de corte de 10 anos com bancos de dados do DATASUS. Arquivos Brasileiros de Cardiologia.

Gioia, R. et al. 2022. Artificial intelligence in hypertension management: an ace up your sleeve. Journal of Cardiovascular Development and Disease 9(8): 268.

Hair, J. F. et al. **Multivariate Data Analysis. 8. ed. Boston: Cengage Learning, 2018.**

He, H.; Garcia, E. A. 2009. Learning from imbalanced data. IEEE Transactions on Knowledge and Data Engineering 21(9): 1263-1284.

Hosmer, D. W. et al. Applied Logistic Regression. 3. ed. Hoboken: John Wiley & Sons, 2013.

Japkowicz, N.; Stephen, S. 2002. The class imbalance problem: A systematic study. *Intelligent Data Analysis* 6(5): 429-449.

Kaplan, E. L.; Meier, P. 1958. Nonparametric estimation from incomplete observations. *Journal of the American Statistical Association* 53(282): 457-481.

Katzman, J. L. et al. 2018. DeepSurv: personalized treatment recommender system using a Cox proportional hazards deep neural network. *BMC Medical Research Methodology*.

Ke, G. et al. 2017. LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems* 30.

Koike, M. 2025. Mini editorial - DataSUS: uma ferramenta essencial para a saúde pública no Brasil. *Arquivos Brasileiros de Cardiologia*.

Kuhn, M.; Johnson, K. *Applied Predictive Modeling*. Nova York: Springer, 2013.

Mehta, L. S. et al. Acute Myocardial Infarction in Women: A Scientific Statement From the American Heart Association. *Circulation* 133(9): 916-947, 2016.

Ministério da Saúde [MS]. 2026. Infarto. Disponível em: <https://www.gov.br/saude/pt-br/assuntos/saude-de-a-a-z/i/infarto>. Acesso em: 19 mar. 2026.

Organização Mundial da Saúde [OMS]. 2026. Cardiovascular diseases. Disponível em: [https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-\(cvds\)](https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds)). Acesso em: 19 mar. 2026.

Précoma, D. B. et al. 2019. Atualização da diretriz de prevenção cardiovascular da Sociedade Brasileira de Cardiologia – 2019. *Arquivos Brasileiros de Cardiologia* 113(4): 787-891.

Ribeiro, G. J. S. et al. 2021. Prevalência de internações e mortalidade por diabetes mellitus e hipertensão arterial sistêmica em Manaus: uma análise de dados do DATASUS. *Saúde (Santa Maria)* 47(1).

Saito, T.; Rehmsmeier, M. 2015. The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. PLOS ONE 10(3).

Sasso, M. T. N. et al. 2024. Infarto agudo do miocárdio e seus manejos na emergência cardiológica: revisão sistemática. Brazilian Journal of Implantology and Health Sciences 6(4): 1634-1652.

Apêndice ou Anexo (opcional)

Os apêndices são textos e/ou documentos que foram elaborados pelos autores e que são importantes para complementar a argumentação do trabalho. Já os anexos são textos ou documentos que ilustram o trabalho, mas que não foram elaborados pelos autores. Os apêndices deverão seguir as mesmas normas de formatação do restante do texto, inclusive para as figuras e tabelas.

O TCC deverá conter no máximo 30 páginas, incluindo o(s) Apêndice(s) e/ou Anexo(s). Aos TCCs dos cursos de **Data Science e Analytics e Engenharia de Software** que possuem temática de **Implementação de Algoritmo(s) de Machine Learning** é facultado o máximo de 50 páginas, incluindo o(s) Apêndice(s) e/ou Anexo(s).

Atenção: antes de enviar o arquivo para o Sistema de TCCs, remova todas as instruções originais que estão abaixo do conteúdo dos tópicos.